

ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC SÀI GÒN

KHOA CÔNG NGHỆ THÔNG TIN

PHAN ĐỨC NHÂN

VÕ GIA KIỆT

Xây dựng và so sánh mô hình cho bài toán phân loại cảm
xúc bình luận trong thương mại điện tử sử dụng phương
pháp truyền thống và Transformer

ĐỒ ÁN CHUYÊN NGÀNH

NGÀNH: CÔNG NGHỆ THÔNG TIN

Thành phố Hồ Chí Minh, năm 2026

ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN

PHAN ĐỨC NHÂN
VÕ GIA KIỆT

Xây dựng và so sánh mô hình cho bài toán phân loại cảm
xúc bình luận trong thương mại điện tử sử dụng phương
pháp truyền thống và Transformer

ĐỒ ÁN CHUYÊN NGÀNH
NGÀNH: CÔNG NGHỆ THÔNG TIN

GIẢNG VIÊN HƯỚNG DẪN:
TS. PHAN TẤN QUỐC

Thành phố Hồ Chí Minh, năm 2026

Lời Cam Đoan

Chúng tôi tên là **Phan Đức Nhân** và **Võ Gia Kiệt**, sinh viên Khoa Công nghệ Thông tin Trường Đại học Sài Gòn, xin cam đoan rằng:

Đồ án chuyên ngành với đề tài “**Xây dựng và so sánh mô hình cho bài toán phân loại cảm xúc bình luận trong thương mại điện tử sử dụng phương pháp truyền thống và Transformer**” là công trình nghiên cứu do chính chúng tôi thực hiện dưới sự hướng dẫn của **TS. Phan Tấn Quốc**.

Các kết quả, nội dung và nhận xét được trình bày trong báo cáo là trung thực, được thực hiện trên cơ sở tìm hiểu lý thuyết, khảo sát tài liệu, xây dựng mô hình và thực nghiệm của nhóm. Những số liệu, bảng biểu, hình ảnh, kết quả nghiên cứu và ý tưởng kế thừa từ các tác giả khác đều đã được trích dẫn nguồn đầy đủ trong phần nội dung và danh mục tài liệu tham khảo.

Chúng tôi xin chịu hoàn toàn trách nhiệm về tính trung thực và tính nguyên bản của nội dung đồ án này. Nếu có sai phạm liên quan đến học thuật, trích dẫn hoặc bản quyền, chúng tôi xin hoàn toàn chịu trách nhiệm theo quy định của Nhà trường.

Thành phố Hồ Chí Minh, ngày 12 tháng 4 năm 2026

Sinh viên thực hiện

(Ký và ghi rõ họ tên)

PHAN ĐỨC NHÂN VÕ GIA KIẾT

Lời Cảm Ơn

Trước hết, chúng tôi xin bày tỏ lòng biết ơn sâu sắc đến **TS. Phan Tấn Quốc**, giảng viên hướng dẫn, đã tận tình định hướng, góp ý chuyên môn và hỗ trợ chúng tôi trong suốt quá trình thực hiện đồ án chuyên ngành này.

Chúng tôi xin chân thành cảm ơn **Quý Thầy, Cô Khoa Công nghệ Thông tin – Trường Đại học Sài Gòn** đã trang bị cho chúng tôi những kiến thức nền tảng và chuyên môn cần thiết trong suốt quá trình học tập, tạo điều kiện để chúng tôi có thể thực hiện đề tài này.

Chúng tôi cũng xin cảm ơn gia đình, bạn bè và các anh chị đã luôn động viên, hỗ trợ và tạo điều kiện thuận lợi để chúng tôi hoàn thành báo cáo giữa kỳ của đồ án.

Mặc dù đã rất cố gắng trong quá trình thực hiện, do hạn chế về thời gian, kinh nghiệm nghiên cứu và phạm vi của báo cáo giữa kỳ, nội dung báo cáo khó tránh khỏi những thiếu sót. Chúng tôi rất mong nhận được những ý kiến đóng góp quý báu từ Quý Thầy, Cô để có thể tiếp tục hoàn thiện đề tài trong giai đoạn tiếp theo.

Xin chân thành cảm ơn.

Danh Mục Các Ký Hiệu, Các Chữ Viết Tắt

Chữ viết tắt	Diễn giải
BERT	Bidirectional Encoder Representations from Transformers
BoW	Bag-of-Words
CPU	Central Processing Unit
F1-score	Trung bình điều hòa của Precision và Recall
GPU	Graphics Processing Unit
LR	Logistic Regression
LSTM	Long Short-Term Memory
NB	Naive Bayes
NEG	Negative (cảm xúc tiêu cực)
NEU	Neutral (cảm xúc trung lập)
NLP	Natural Language Processing / Xử lý ngôn ngữ tự nhiên
POS	Positive (cảm xúc tích cực)
RNN	Recurrent Neural Network
SGU	Saigon University / Trường Đại học Sài Gòn
SVM	Support Vector Machine
TF-IDF	Term Frequency – Inverse Document Frequency
TMĐT	Thương mại điện tử

Danh Mục Các Biểu Bảng

Bảng 2.1. Tập dữ liệu và nhãn tương ứng

Bảng 2.4.1.1. Các tham số dùng để thử nghiệm cơ bản cho vectorizer và mô hình LR

Bảng 2.4.2.1 Các tham số dùng để thử nghiệm cơ bản cho vectorizer và mô hình PhoBert

Bảng 2.6.1. Cấu hình môi trường thực nghiệm

Bảng 3.1.3.1. Ghi chú cài đặt, tham số và đầu ra huấn luyện của hai mô hình

Bảng 3.2.1.1. Kết quả đánh giá tổng thể của mô hình TF-IDF kết hợp Logistic Regression

Bảng 3.3.1.1. Kết quả đánh giá tổng thể huấn luyện mô hình PhoBert

Bảng 3.4.2.1. So sánh hiệu suất giữa mô hình

Bảng 3.4.2.2 Đánh giá mô hình theo từng lớp

Bảng 3.4.3.1. So sánh về thời gian huấn luyện, suy luận và tài nguyên giữa hai mô hình

Bảng 3.5.2.1. Phân bố lỗi theo từng lớp cảm xúc của mô hình TF-IDF kết hợp Logistic Regression

Bảng 3.5.3.1 Phân tích lỗi theo từng lớp

Bảng 3.5.4.1 Tóm tắt các lỗi chính

Bảng 3.5.7.1 So sánh lỗi giữa 2 mô hình

Bảng 3.6.1.1. thông tin thiết lập thử nghiệm chung

Bảng 3.6.2.1 So sánh chi phí tính toán

Bảng 3.6.3.1. Ưu và nhược điểm của 2 mô hình

Danh Mục Các Hình Ảnh, Sơ Đồ

Hình 2.2.1. Quy mô dữ liệu, phân bố số lượng

Hình 2.2.2 Độ dài trung bình bình luận, tỷ lệ dữ liệu lệch so với nhãn thật

Hình 2.2.3. Phân bố các chủ đề phổ biến trong bình luận thương mại điện tử

Hình 2.3.1. Quy trình tiền xử lý cho mô hình LogisticRegression

Hình 2.3.2. Quy trình tiền xử lý cho mô hình PhoBERT

Hình 2.4.1. Sơ đồ kiến trúc của mô hình TF-IDF kết hợp Logistic Regression

Hình 2.4.2. Sơ đồ kiến trúc PhoBERT

Hình 3.1.2.1. Fine Tuning mô hình PhoBert

Hình 3.3.1.1. Sơ đồ epoch và loss mô hình PhoBert

Hình 3.4.1.1. So Sánh hiệu suất theo từng lớp

Hình 3.4.1.2. So Sánh hiệu suất theo Accuracy

Hình 3.4.2.1. Confusion Maxtrix

Hình 3.5.7.1. Phân tích các loại lỗi của mô hình PhoBert

MỤC LỤC

Lời Cam Đoan	i
Lời Cảm Ơn	ii
Danh mục các ký hiệu ,các chữ viết tắt.....	iii
Danh mục các biểu bảng	iv
Danh mục các hình ảnh, sơ đồ	v
LỜI MỞ ĐẦU.....	4
CHƯƠNG 1 : Tổng quan và cơ sở lý thuyết về phân loại cảm xúc bình luận Thương Mại Điện Tử.....	6
1.1. Bài toán phân loại cảm xúc	6
1.2. Đặc thù dữ liệu bình luận thương mại điện tử	8
1.3. Ứng dụng và thách thức	10
1.4. Tiêu chí đánh giá mô hình	11
1.5. Khảo sát các công trình nghiên cứu liên quan	12
1.5.1 Nhóm mô hình truyền thống trong phân loại văn bản.	13
1.5.2 Nhóm mô hình Transformer cho phân loại văn bản	13
1.6. Định hướng thực hiện của đề tài	14
1.7. Tóm tắt chương 1	15
CHƯƠNG 2 : Phương pháp nghiên cứu và xây dựng mô hình.....	16
2.1. Thiết kế thực nghiệm cho bài toán phân loại cảm xúc	16
2.2. Dữ liệu nghiên cứu.....	16
2.3. Tiền xử lý văn bản tiếng Việt cho bình luận TMĐT	20
2.4. Mô hình và cấu hình thực nghiệm	21
2.4.1. TF-IDF kết hợp Logistic Regression	22
2.4.2. PhoBERT fine-tuning cho sequence classification.....	24

2.5. Thiết lập huấn luyện và tiêu chí đánh giá	27
2.6. Môi trường thực nghiệm	28
2.7. Tóm tắt chương 2	29
CHƯƠNG 3 : Kết quả thực nghiệm và thảo luận.....	30
3.1. Quy trình triển khai và huấn luyện mô hình	30
3.1.1. Quy trình triển khai mô hình TF-IDF kết hợp Logistic Regression	33
3.1.2. Quy trình triển khai mô hình PhoBert	36
3.1.3. Ghi chú cài đặt, tham số và đầu ra huấn luyện	44
3.2. Kết quả thực nghiệm của mô hình TF-IDF kết hợp Logistic Regression.....	46
3.2.1. Kết quả huấn luyện và đánh giá tổng thể.....	46
3.2.2. Nhận xét kết quả của mô hình	48
3.3. Kết quả thực nghiệm của mô hình PhoBert.....	49
3.3.1. Kết quả huấn luyện và đánh giá tổng thể.....	49
3.3.2. Nhận xét kết quả của mô hình	52
3.4. So sánh tổng quan và đánh giá hiệu năng giữa hai mô hình.....	52
3.4.1. So sánh hiệu suất từng lớp	52
3.4.2. So sánh theo các chỉ số đánh giá.....	54
3.4.2. So sánh về thời gian huấn luyện, suy luận và tài nguyên	57
3.4.3. Nhận xét tổng hợp.....	59
3.5. Phân tích lỗi	60
3.5.1 Mục tiêu phân tích lỗi	60
3.5.2 Phân bố lỗi theo từng lớp của mô hình TF-IDF kết hợp Logistic Regression .	61
3.5.3 Phân bố lỗi theo từng lớp của mô hình PhoBert.....	61
3.5.4 Phân tích các dạng lỗi chính	62
3.5.7 So sánh lỗi giữa 2 mô hình	64
3.5.8 Kết luận phân tích lỗi.....	66
3.6. Đánh giá khả năng triển khai và đề xuất lựa chọn mô hình	67

3.6.1 Thiết lập thử nghiệm.....	67
3.6.2 So sánh khả năng triển khai	67
3.6.3 Tổng hợp ưu nhược điểm.....	68
3.6.4 Đề xuất lựa chọn mô hình.....	69
3.7. Tóm tắt chương 3	70
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	72
Tài liệu tham khảo	76
PHỤ LỤC.....	78

LỜI MỞ ĐẦU

Trong những năm gần đây, thương mại điện tử đã trở thành một trong những lĩnh vực phát triển mạnh mẽ nhất của nền kinh tế số. Cùng với sự gia tăng nhanh chóng của các sản phẩm dịch vụ trực tuyến, lượng bình luận và đánh giá của người dùng về sản phẩm, dịch vụ cũng ngày càng lớn. Những bình luận này không chỉ phản ánh mức độ hài lòng của khách hàng mà còn chứa nhiều thông tin quan trọng liên quan đến chất lượng sản phẩm, trải nghiệm mua sắm, dịch vụ chăm sóc khách hàng và xu hướng tiêu dùng. Do đó, việc khai thác và phân tích hiệu quả nguồn dữ liệu này có ý nghĩa rất lớn đối với doanh nghiệp cũng như các hệ thống hỗ trợ ra quyết định.

Trong lĩnh vực xử lý ngôn ngữ tự nhiên, phân loại cảm xúc văn bản là một bài toán quan trọng và có nhiều ứng dụng thực tiễn. Mục tiêu của bài toán là xác định cảm xúc hoặc quan điểm được thể hiện trong văn bản, chẳng hạn như tích cực, tiêu cực hoặc trung lập. Đối với dữ liệu bình luận thương mại điện tử bằng tiếng Việt, việc phân loại cảm xúc càng trở nên cần thiết vì doanh nghiệp có thể dựa vào đó để đánh giá phản hồi khách hàng trên quy mô lớn, phát hiện vấn đề của sản phẩm và kịp thời điều chỉnh chiến lược kinh doanh.

Tuy nhiên, dữ liệu bình luận trên các nền tảng thương mại điện tử thường mang tính không chuẩn hóa cao. Người dùng có xu hướng sử dụng câu ngắn, viết tắt, tiếng lóng, ký tự đặc biệt, biểu tượng cảm xúc, thậm chí pha trộn giữa tiếng Việt và tiếng Anh. Ngoài ra, tiếng Việt là ngôn ngữ có đặc thù riêng về từ ghép, dấu thanh và cách biểu đạt ngữ nghĩa, làm cho bài toán xử lý và phân loại cảm xúc trở nên phức tạp hơn. Điều này đặt ra yêu cầu cần nghiên cứu và lựa chọn mô hình phù hợp để vừa đảm bảo hiệu quả phân loại, vừa phù hợp với điều kiện dữ liệu và tài nguyên tính toán.

Hiện nay, bài toán phân loại cảm xúc được tiếp cận theo nhiều hướng khác nhau. Một trong những hướng phổ biến là sử dụng các mô hình truyền thống dựa trên biểu diễn đặc trưng văn bản như TF-IDF kết hợp với các thuật toán học máy cổ điển, điển hình là Logistic Regression. Hướng tiếp cận này có ưu điểm là đơn giản, dễ triển khai, tốc độ huấn luyện nhanh và thường được sử dụng làm mô hình cơ sở để so sánh. Bên cạnh đó, sự phát triển của các mô hình học sâu, đặc biệt là kiến trúc Transformer, đã mở ra nhiều bước tiến quan trọng trong xử lý ngôn ngữ tự nhiên. Đối với tiếng Việt, PhoBERT là một trong những mô

hình tiêu biểu cho thấy khả năng nắm bắt ngữ cảnh và biểu diễn ngữ nghĩa sâu hiệu quả hơn so với các phương pháp truyền thống.

Xuất phát từ những lý do trên, nhóm lựa chọn đề tài “Nghiên cứu và so sánh mô hình truyền thống và Transformer cho bài toán phân loại cảm xúc bình luận thương mại điện tử”. Đề tài tập trung vào việc xây dựng, thực nghiệm và so sánh hai hướng tiếp cận tiêu biểu gồm mô hình TF-IDF kết hợp Logistic Regression và mô hình PhoBERT fine-tuning cho bài toán phân loại cảm xúc tiếng Việt. Thông qua quá trình thực nghiệm trên cùng một tập dữ liệu và cùng tiêu chí đánh giá, nghiên cứu hướng đến việc làm rõ ưu điểm, hạn chế và khả năng ứng dụng của từng mô hình trong điều kiện thực tế.

Về mặt học thuật, đề tài góp phần hệ thống hóa cơ sở lý thuyết liên quan đến bài toán phân loại cảm xúc, biểu diễn đặc trưng văn bản, mô hình học máy truyền thống và mô hình Transformer cho tiếng Việt. Về mặt thực tiễn, nghiên cứu giúp cung cấp cơ sở tham khảo cho việc lựa chọn mô hình phù hợp trong các hệ thống phân tích phản hồi khách hàng trên nền tảng thương mại điện tử. Kết quả nghiên cứu có thể là cơ sở để phát triển các ứng dụng hỗ trợ doanh nghiệp trong quản lý chất lượng sản phẩm, chăm sóc khách hàng và phân tích hành vi người tiêu dùng.

Ngoài phần mở đầu, kết luận, tài liệu tham khảo và phụ lục, báo cáo gồm hai chương chính trong giai đoạn giữa kỳ. Chương 1 trình bày tổng quan và cơ sở lý thuyết về bài toán phân loại cảm xúc bình luận thương mại điện tử, bao gồm khái niệm, đặc thù dữ liệu, tiêu chí đánh giá và các nhóm mô hình liên quan. Chương 2 trình bày phương pháp nghiên cứu và xây dựng mô hình, bao gồm mô tả bài toán, dữ liệu nghiên cứu, quy trình tiền xử lý, xây dựng mô hình baseline TF-IDF kết hợp Logistic Regression, mô hình PhoBERT fine-tuning, thiết lập huấn luyện và môi trường thực nghiệm. Nội dung này phù hợp với cấu trúc trình bày ĐACN của trường và quy định bố cục các chương trong phần nội dung chính.

CHƯƠNG 1 : Tổng quan và cơ sở lý thuyết về phân loại cảm xúc bình luận Thương Mại Điện Tử

1.1. Bài toán phân loại cảm xúc

Phân loại cảm xúc văn bản (sentiment classification hoặc sentiment analysis) là một bài toán quan trọng trong lĩnh vực xử lý ngôn ngữ tự nhiên, nhằm xác định thái độ, quan điểm hoặc cực tính cảm xúc được biểu đạt trong văn bản. Theo Jurafsky và Martin, đây có thể được xem là một dạng của bài toán phân loại văn bản, trong đó mục tiêu là tự động gán nhãn cảm xúc cho văn bản dựa trên nội dung ngôn ngữ; ở dạng đơn giản nhất, bài toán thường được xây dựng như một bài toán phân loại nhị phân giữa hai lớp tích cực và tiêu cực. Bing Liu cũng xem sentiment analysis là quá trình khai thác ý kiến, cảm xúc và đánh giá của con người từ dữ liệu văn bản.

Trong thực tế, tùy theo mục tiêu ứng dụng và cách xây dựng dữ liệu, bài toán phân loại cảm xúc có thể được tổ chức dưới dạng hai lớp hoặc nhiều lớp. Với phân loại hai lớp, văn bản thường được gán vào một trong hai nhãn tích cực hoặc tiêu cực. Với phân loại ba lớp, ngoài hai nhãn trên còn có thêm lớp trung lập để biểu diễn những trường hợp văn bản không thể hiện rõ khuynh hướng cảm xúc. Hướng tiếp cận này đã được sử dụng từ sớm trong các công trình kinh điển về sentiment classification, trong đó nghiên cứu của Pang, Lee và Vaithyanathan là một trong những công trình đặt nền móng cho việc áp dụng các kỹ thuật học máy vào phân loại cảm xúc văn bản.

Trong bối cảnh thương mại điện tử, bài toán phân loại cảm xúc thường được áp dụng trên các bình luận, đánh giá và phản hồi của người dùng đối với sản phẩm hoặc dịch vụ. Đây là nguồn dữ liệu có giá trị vì phản ánh trực tiếp trải nghiệm thực tế, mức độ hài lòng và quan điểm của khách hàng sau quá trình sử dụng sản phẩm. Khi được xử lý hiệu quả, các dữ liệu này có thể hỗ trợ doanh nghiệp theo dõi chất lượng sản phẩm, phát hiện các vấn đề phát sinh, đánh giá phản hồi của thị trường và hỗ trợ quá trình ra quyết định. Về bản chất, đây là một ứng dụng cụ thể của bài toán opinion mining trong môi trường số.

Về mặt phương pháp, các hướng tiếp cận cho bài toán phân loại cảm xúc đã phát triển qua nhiều giai đoạn. Ở giai đoạn đầu, các mô hình học máy truyền thống thường sử dụng các

cách biểu diễn văn bản như Bag-of-Words hoặc TF-IDF, sau đó áp dụng các bộ phân loại như Naive Bayes, Support Vector Machine hoặc Logistic Regression. Các công trình đầu tiên cho thấy những mô hình này có thể đạt hiệu quả tốt khi dữ liệu được tiền xử lý và biểu diễn phù hợp. Tuy nhiên, hạn chế chính của nhóm phương pháp này là phụ thuộc nhiều vào đặc trưng bề mặt của từ ngữ và chưa khai thác tốt ngữ cảnh sâu của câu.

Một bước chuyển quan trọng trong xử lý ngôn ngữ tự nhiên xuất hiện với kiến trúc Transformer do Vaswani và cộng sự đề xuất năm 2017. Kiến trúc này dựa trên cơ chế attention, cho phép mô hình học quan hệ phụ thuộc giữa các từ trong chuỗi hiệu quả hơn so với các kiến trúc tuần tự trước đó. Trên nền tảng đó, BERT của Devlin và cộng sự tiếp tục mở rộng khả năng biểu diễn bằng cách tiền huấn luyện biểu diễn ngôn ngữ hai chiều sâu từ dữ liệu văn bản lớn không gán nhãn, qua đó tạo ra bước tiến đáng kể cho nhiều tác vụ NLP, trong đó có phân loại văn bản và phân loại cảm xúc.

Đối với tiếng Việt, các mô hình ngôn ngữ tiền huấn luyện chuyên biệt đã mở ra khả năng cải thiện đáng kể hiệu quả xử lý ngôn ngữ. Tiêu biểu là PhoBERT, được Nguyen và Nguyen giới thiệu năm 2020 như một trong những mô hình ngôn ngữ đơn ngữ quy mô lớn đầu tiên cho tiếng Việt. Kết quả công bố cho thấy PhoBERT vượt trội hơn các mô hình đa ngữ trước đó trên nhiều tác vụ xử lý tiếng Việt, nhờ khả năng học biểu diễn ngôn ngữ phù hợp hơn với đặc trưng riêng của tiếng Việt. Điều này cho thấy việc áp dụng các mô hình Transformer chuyên biệt cho tiếng Việt là một hướng tiếp cận có tiềm năng cao trong bài toán phân loại cảm xúc.

Tuy nhiên, đối với dữ liệu bình luận thương mại điện tử tiếng Việt, bài toán này vẫn gặp không ít khó khăn. Ngôn ngữ trong bình luận thường mang tính không chuẩn hóa, có thể chứa từ viết tắt, cách viết không dấu, biểu tượng cảm xúc, từ địa phương hoặc sự pha trộn giữa tiếng Việt và tiếng Anh. Bên cạnh đó, sắc thái cảm xúc trong tiếng Việt còn chịu ảnh hưởng mạnh bởi ngữ cảnh, phủ định, mức độ nhấn mạnh và cách diễn đạt đời thường. Vì vậy, việc xây dựng và so sánh các mô hình phân loại cảm xúc trên dữ liệu tiếng Việt là cần thiết, không chỉ về mặt kỹ thuật mà còn có ý nghĩa thực tiễn đối với các hệ thống hỗ trợ phân tích phản hồi khách hàng trong thương mại điện tử. Phần còn lại của đề tài sẽ tập trung vào việc xây dựng hai hướng tiếp cận tiêu biểu gồm **TF-IDF kết hợp Logistic Regression** và **PhoBERT**, sau đó đánh giá và so sánh hiệu quả của chúng trên cùng một quy trình thực nghiệm thống nhất.

1.2. Đặc thù dữ liệu bình luận thương mại điện tử

Trong các bài toán xử lý ngôn ngữ tự nhiên nói chung và bài toán phân loại cảm xúc văn bản nói riêng, dữ liệu đóng vai trò nền tảng quyết định hiệu quả của mô hình. Chất lượng, cấu trúc và đặc điểm của dữ liệu ảnh hưởng trực tiếp đến khả năng học và dự đoán của các thuật toán học máy. Đối với bài toán phân loại cảm xúc bình luận thương mại điện tử tiếng Việt, dữ liệu thường được thu thập từ các nền tảng trực tuyến như các trang thương mại điện tử, diễn đàn hoặc ứng dụng mua sắm, nơi người dùng để lại bình luận và đánh giá về sản phẩm hoặc dịch vụ. Những bình luận này phản ánh mức độ hài lòng, quan điểm cũng như trải nghiệm thực tế của khách hàng đối với sản phẩm.

Thông thường, một tập dữ liệu cho bài toán phân loại cảm xúc bao gồm hai thành phần chính: **nội dung văn bản (content)** và **nhãn cảm xúc (label)**. Nội dung văn bản là các bình luận hoặc đánh giá của người dùng, trong khi nhãn cảm xúc thể hiện thái độ hoặc cảm xúc của người viết đối với sản phẩm hoặc dịch vụ. Tùy theo cách xây dựng bài toán, nhãn cảm xúc có thể được chia thành hai lớp như tích cực và tiêu cực, hoặc ba lớp như tích cực, trung tính và tiêu cực.

Trong đề tài này, nhóm sử dụng bộ dữ liệu **Vietnamese Sentiment Analysis Dataset** được công bố trên nền tảng Kaggle để phục vụ cho quá trình huấn luyện và đánh giá mô hình. Bộ dữ liệu này bao gồm các bình luận tiếng Việt kèm theo nhãn cảm xúc tương ứng, phù hợp với mục tiêu xây dựng và so sánh các mô hình phân loại cảm xúc. Dataset được truy cập tại :

<https://www.kaggle.com/datasets/linhlpv/vietnamese-sentiment-analyst>

So với các dạng văn bản chuẩn như sách, báo hoặc tài liệu học thuật, dữ liệu bình luận trong thương mại điện tử có nhiều đặc điểm riêng biệt. Trước hết, đây là loại dữ liệu thường có **độ dài ngắn**, không đồng nhất về hình thức và mang tính tự phát cao. Người dùng có thể chỉ để lại một vài từ để bày tỏ cảm xúc, chẳng hạn như “rất tốt”, “quá tệ”, “đóng gói ổn”, hoặc một câu ngắn không đầy đủ thành phần ngữ pháp. Độ dài ngắn và cấu trúc không hoàn chỉnh khiến việc phân tích ngữ nghĩa trở nên khó khăn hơn.

Một đặc điểm nổi bật khác là **tính không chuẩn hóa cao**. Trong thực tế, người dùng thường sử dụng từ viết tắt, tiếng lóng, lỗi chính tả, kéo dài ký tự để nhấn mạnh cảm xúc, emoji, ký tự đặc biệt hoặc pha trộn giữa tiếng Việt và tiếng Anh. Ví dụ, cùng một ý khen sản phẩm, người dùng có thể viết dưới nhiều dạng khác nhau như “ok”, “ôn áp”, “xịn”, “good”, “sp quá oke” hoặc “ship nhanhhhh”. Sự đa dạng này làm gia tăng độ phức tạp cho quá trình tiền xử lý và chuẩn hóa dữ liệu.

Bên cạnh đó, dữ liệu bình luận thương mại điện tử còn có **tính đa chiều về nội dung**. Trong cùng một bình luận, người dùng có thể vừa khen một khía cạnh, vừa chê một khía cạnh khác của sản phẩm hoặc dịch vụ. Chẳng hạn, một bình luận có thể đánh giá tích cực về chất lượng sản phẩm nhưng lại không hài lòng về thời gian giao hàng. Điều này làm cho việc gán nhãn cảm xúc ở mức toàn bộ bình luận trở nên không đơn giản, đặc biệt khi bài toán được xây dựng theo hướng phân loại cảm xúc ở mức câu hoặc mức bình luận.

Đối với tiếng Việt, dữ liệu văn bản còn chịu ảnh hưởng của các đặc trưng ngôn ngữ riêng như từ ghép đa âm tiết, hiện tượng đồng âm khác nghĩa, cách viết không dấu hoặc sai dấu, cũng như nhiều biến thể diễn đạt cùng một ý nghĩa. Nếu quá trình tách từ và chuẩn hóa không tốt, ý nghĩa của câu có thể bị thay đổi, từ đó ảnh hưởng trực tiếp đến chất lượng biểu diễn dữ liệu và hiệu quả của mô hình.

Ngoài ra, dữ liệu bình luận trên các nền tảng thương mại điện tử thường có hiện tượng **mất cân bằng nhãn**. Trong thực tế, số lượng bình luận tích cực thường lớn hơn đáng kể so với bình luận tiêu cực hoặc trung tính. Hiện tượng lệch lớp này ảnh hưởng trực tiếp đến quá trình huấn luyện và đánh giá mô hình, vì mô hình có thể thiên lệch về lớp xuất hiện nhiều hơn. Do đó, đây là một yếu tố cần được xem xét khi thiết kế thí nghiệm và lựa chọn chỉ số đánh giá.

Từ những đặc điểm trên có thể thấy rằng dữ liệu bình luận thương mại điện tử tiếng Việt vừa có giá trị ứng dụng cao, vừa đặt ra nhiều thách thức trong quá trình xử lý ngôn ngữ tự nhiên. Việc hiểu rõ nguồn dữ liệu, cấu trúc dữ liệu và các đặc trưng ngôn ngữ của loại dữ liệu này là cơ sở quan trọng để lựa chọn phương pháp tiền xử lý, cách biểu diễn văn bản và mô hình phân loại phù hợp trong các phần tiếp theo của đề tài.

1.3. Ứng dụng và thách thức

Phân loại cảm xúc bình luận thương mại điện tử có nhiều ứng dụng thực tiễn trong cả hoạt động kinh doanh lẫn nghiên cứu. Trước hết, kết quả phân loại cảm xúc giúp doanh nghiệp nhanh chóng nắm bắt phản hồi của khách hàng đối với sản phẩm và dịch vụ. Thông qua việc tổng hợp số lượng bình luận tích cực, tiêu cực và trung lập, doanh nghiệp có thể đánh giá xu hướng hài lòng chung của khách hàng mà không cần đọc thủ công từng bình luận.

Bên cạnh đó, phân tích cảm xúc còn hỗ trợ phát hiện các vấn đề tồn tại trong sản phẩm hoặc quy trình bán hàng. Khi một nhóm lớn bình luận mang cảm xúc tiêu cực tập trung vào một loại sản phẩm hoặc một thời điểm nhất định, doanh nghiệp có thể nhận biết sớm dấu hiệu bất thường để kiểm tra nguyên nhân. Đây là cơ sở quan trọng cho hoạt động quản lý chất lượng, chăm sóc khách hàng và cải tiến sản phẩm.

Trong marketing và quản trị thương hiệu, phân loại cảm xúc giúp doanh nghiệp theo dõi hình ảnh thương hiệu trong mắt người tiêu dùng. Việc phân tích tự động các phản hồi từ người dùng giúp doanh nghiệp đánh giá hiệu quả của chiến dịch quảng bá, phản ứng của thị trường đối với sản phẩm mới và những thay đổi trong hành vi khách hàng. Ngoài ra, kết quả phân loại cảm xúc còn có thể được tích hợp vào hệ thống gợi ý sản phẩm, hệ thống hỗ trợ khách hàng hoặc bảng điều khiển phân tích dữ liệu cho quản lý.

Mặc dù có nhiều ứng dụng, bài toán phân loại cảm xúc cũng tồn tại nhiều thách thức. Một trong những khó khăn lớn nhất là sự đa dạng và không chuẩn của ngôn ngữ người dùng. Bình luận có thể ngắn, mơ hồ, có nhiều lỗi chính tả hoặc sử dụng biểu đạt gián tiếp. Nhiều trường hợp cảm xúc không được thể hiện rõ bằng từ ngữ đánh giá trực tiếp mà được truyền tải qua ngữ cảnh, cách nhấn mạnh hoặc sắc thái mỉa mai.

Một thách thức khác là hiện tượng dữ liệu lệch lớp. Trong các tập dữ liệu thực tế, bình luận tích cực thường xuất hiện nhiều hơn, trong khi bình luận tiêu cực hoặc trung lập ít hơn. Khi huấn luyện trên dữ liệu không cân bằng, mô hình có thể đạt độ chính xác tổng thể cao nhưng lại hoạt động kém ở các lớp thiểu số. Vì vậy, nếu chỉ sử dụng accuracy để đánh giá thì có thể không phản ánh đúng chất lượng mô hình.

Đối với tiếng Việt, bài toán còn gặp khó khăn từ đặc trưng ngôn ngữ như tách từ, chuẩn hóa chính tả, xử lý từ ghép, từ lỏng và biểu thức mang tính khẩu ngữ. Ngoài ra, mô hình cần đủ khả năng nhận diện ngữ cảnh để hiểu được sự khác biệt giữa những câu có cấu trúc bề mặt tương tự nhưng sắc thái cảm xúc khác nhau. Đây là lý do các mô hình hiện đại như Transformer ngày càng được quan tâm trong bài toán này.

Nhìn chung, phân loại cảm xúc bình luận thương mại điện tử là một bài toán có giá trị ứng dụng cao nhưng cũng đi kèm với nhiều khó khăn về dữ liệu, ngôn ngữ và thiết kế mô hình. Chính vì vậy, việc nghiên cứu, thực nghiệm và so sánh các hướng tiếp cận khác nhau là cần thiết để tìm ra giải pháp phù hợp trong từng điều kiện cụ thể.

1.4. Tiêu chí đánh giá mô hình

Để đánh giá hiệu quả của mô hình phân loại cảm xúc, cần sử dụng các chỉ số đo lường phù hợp nhằm phản ánh đúng năng lực của mô hình trên tập dữ liệu kiểm tra. Trong bài toán phân loại văn bản, đặc biệt là khi dữ liệu có thể lệch lớp, việc đánh giá không nên chỉ dựa vào một chỉ số duy nhất mà cần kết hợp nhiều thước đo khác nhau.

Chỉ số đầu tiên thường được sử dụng là accuracy. Đây là tỷ lệ giữa số mẫu dự đoán đúng và tổng số mẫu trong tập kiểm tra. Accuracy cho biết mức độ đúng chung của mô hình trên toàn bộ dữ liệu. Tuy nhiên, chỉ số này có hạn chế trong trường hợp dữ liệu mất cân bằng, vì mô hình có thể đạt accuracy cao dù dự đoán kém ở lớp thiểu số.

$$Accuracy = \frac{\text{correct classifications}}{\text{total classification}} = \frac{TP + TN}{TP + TN + FP + FN}$$

Bên cạnh accuracy, precision là chỉ số đo mức độ chính xác của các dự đoán thuộc một lớp nhất định. Cụ thể, precision cho biết trong số các mẫu mà mô hình dự đoán là tích cực hoặc tiêu cực, có bao nhiêu mẫu thực sự thuộc lớp đó. Chỉ số này quan trọng trong các trường hợp cần hạn chế dự đoán sai dương tính.

$$Precision = \frac{\text{correctly classified actual positives}}{\text{everything classified as positive}} = \frac{TP}{TP + FP}$$

Recall là chỉ số phản ánh khả năng phát hiện đầy đủ các mẫu thực sự thuộc một lớp. Recall cho biết trong tổng số các mẫu thực sự thuộc lớp đó, mô hình nhận diện đúng được bao nhiêu. Chỉ số này quan trọng khi cần hạn chế bỏ sót các trường hợp thuộc lớp quan tâm.

$$\text{Recall (or TPR)} = \frac{\text{correctly classified actual positives}}{\text{all actual positives}} = \frac{TP}{TP + FN}$$

F1-score là trung bình điều hòa giữa precision và recall, giúp cân bằng giữa hai tiêu chí trên. Trong nhiều nghiên cứu về phân loại văn bản, F1-score được xem là chỉ số quan trọng vì nó phản ánh tương đối toàn diện chất lượng của mô hình, đặc biệt khi dữ liệu không cân bằng. Ngoài F1-score cho từng lớp, có thể sử dụng macro F1 hoặc weighted F1 để đánh giá tổng thể trên nhiều lớp.

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Ngoài các chỉ số định lượng, confusion matrix cũng là một công cụ quan trọng trong đánh giá mô hình. Ma trận nhầm lẫn cho phép quan sát số lượng mẫu được dự đoán đúng hoặc sai giữa các lớp, từ đó hỗ trợ phân tích lỗi một cách cụ thể hơn. Thông qua confusion matrix, có thể nhận biết mô hình thường nhầm lẫn giữa những lớp nào, ví dụ giữa trung lập và tích cực hoặc giữa tiêu cực và trung lập.

Trong đề tài này, việc đánh giá mô hình được thực hiện dựa trên các chỉ số accuracy, precision, recall và F1-score. Đồng thời, confusion matrix sẽ được sử dụng để hỗ trợ phân tích lỗi và làm rõ hành vi dự đoán của từng mô hình. Việc kết hợp nhiều tiêu chí đánh giá sẽ giúp quá trình so sánh giữa mô hình truyền thống và mô hình Transformer trở nên toàn diện và công bằng hơn.

1.5. Khảo sát các công trình nghiên cứu liên quan

Phân loại cảm xúc (Sentiment Analysis) là một trong những bài toán được nghiên cứu từ sớm trong lĩnh vực xử lý ngôn ngữ tự nhiên (Natural Language Processing – NLP). Trong nhiều năm qua, các nghiên cứu đã đề xuất nhiều phương pháp khác nhau nhằm cải thiện

hiệu quả phân loại văn bản, từ các mô hình học máy truyền thống cho đến các mô hình học sâu hiện đại. Nhìn chung, các hướng nghiên cứu trong phân loại cảm xúc có thể được chia thành hai nhóm chính: **các mô hình truyền thống dựa trên đặc trưng thủ công** và **các mô hình học sâu dựa trên kiến trúc Transformer**.

1.5.1 Nhóm mô hình truyền thống trong phân loại văn bản.

Các nghiên cứu ban đầu về phân loại cảm xúc chủ yếu sử dụng các mô hình học máy truyền thống kết hợp với các phương pháp biểu diễn văn bản dựa trên tần suất từ. Những kỹ thuật phổ biến nhất bao gồm **Bag-of-Words (BoW)** và **TF-IDF (Term Frequency – Inverse Document Frequency)**. Các phương pháp này chuyển đổi văn bản thành vector số dựa trên tần suất xuất hiện của từ trong tài liệu và toàn bộ tập dữ liệu, từ đó cho phép áp dụng các thuật toán học máy vào bài toán phân loại văn bản.

Trên cơ sở các đặc trưng này, nhiều mô hình học máy đã được áp dụng thành công trong phân loại cảm xúc, tiêu biểu như **Naive Bayes**, **Support Vector Machine (SVM)** và **Logistic Regression**. Các nghiên cứu của Pang và Lee (2002) cho thấy rằng những mô hình truyền thống này có thể đạt kết quả khá tốt trong các bài toán phân loại cảm xúc khi dữ liệu được biểu diễn phù hợp và quá trình tiền xử lý được thực hiện hiệu quả.

Ưu điểm của các mô hình truyền thống là cấu trúc đơn giản, thời gian huấn luyện nhanh và yêu cầu tài nguyên tính toán thấp. Điều này giúp chúng dễ dàng triển khai trong các hệ thống thực tế hoặc khi dữ liệu không quá lớn. Tuy nhiên, hạn chế của các phương pháp này là chúng chủ yếu dựa trên thống kê tần suất từ và chưa thể nắm bắt đầy đủ ngữ cảnh cũng như mối quan hệ ngữ nghĩa giữa các từ trong câu. Vì vậy, hiệu quả của các mô hình này thường bị giới hạn khi xử lý các câu phức tạp hoặc có nhiều cách diễn đạt khác nhau.

1.5.2 Nhóm mô hình Transformer cho phân loại văn bản

Cùng với sự phát triển của học sâu (Deep Learning), các nghiên cứu trong lĩnh vực xử lý ngôn ngữ tự nhiên đã chuyển dần sang các mô hình có khả năng học biểu diễn ngữ nghĩa sâu hơn. Một trong những bước tiến quan trọng là sự ra đời của các mô hình **word embedding**, tiêu biểu như **Word2Vec**, **GloVe** và **fastText**, cho phép biểu diễn từ dưới dạng vector liên tục và nắm bắt tốt hơn mối quan hệ ngữ nghĩa giữa các từ.

Tuy nhiên, bước đột phá lớn trong NLP xuất hiện khi kiến trúc **Transformer** được giới thiệu bởi Vaswani và cộng sự (2017). Transformer sử dụng cơ chế **self-attention**, cho phép mô hình học được mối quan hệ giữa các từ trong toàn bộ câu và nắm bắt ngữ cảnh hai chiều. Trên cơ sở kiến trúc này, nhiều mô hình ngôn ngữ tiên huấn luyện đã được phát triển, trong đó nổi bật là **BERT (Bidirectional Encoder Representations from Transformers)**.

Đối với tiếng Việt, các nghiên cứu gần đây đã áp dụng các mô hình Transformer vào nhiều bài toán NLP, trong đó có phân tích cảm xúc. Một trong những mô hình tiêu biểu là **PhoBERT**, được phát triển dựa trên kiến trúc BERT và được huấn luyện trên tập dữ liệu tiếng Việt quy mô lớn. Nhờ khả năng học biểu diễn ngữ nghĩa sâu và hiểu ngữ cảnh tốt hơn, PhoBERT đã đạt được hiệu quả cao trong nhiều nhiệm vụ xử lý ngôn ngữ tiếng Việt, bao gồm phân loại văn bản và phân tích cảm xúc.

1.6. Định hướng thực hiện của đề tài

Từ cơ sở lý thuyết và các công trình nghiên cứu liên quan đã khảo sát, có thể thấy bài toán phân loại cảm xúc văn bản hiện nay thường được tiếp cận theo hai nhóm phương pháp tiêu biểu: nhóm mô hình học máy truyền thống và nhóm mô hình học sâu dựa trên kiến trúc Transformer. Mỗi nhóm phương pháp đều có những ưu điểm và hạn chế riêng về khả năng biểu diễn ngữ nghĩa, chi phí tính toán và mức độ phù hợp với từng loại dữ liệu.

Trên cơ sở đó, đề tài định hướng nghiên cứu theo hướng xây dựng và đối chiếu hai mô hình đại diện cho hai nhóm tiếp cận này trên dữ liệu bình luận thương mại điện tử tiếng Việt. Cụ thể, nhóm lựa chọn mô hình **TF-IDF kết hợp Logistic Regression** làm hướng tiếp cận truyền thống và mô hình **PhoBERT** làm hướng tiếp cận dựa trên Transformer.

Việc lựa chọn hai mô hình trên nhằm tạo cơ sở để xem xét sự khác biệt giữa phương pháp biểu diễn đặc trưng truyền thống và phương pháp biểu diễn ngữ cảnh sâu trong bài toán phân loại cảm xúc tiếng Việt. Trên nền tảng định hướng này, chương tiếp theo sẽ trình bày cụ thể dữ liệu nghiên cứu, quy trình tiền xử lý, cách xây dựng mô hình và thiết kế thực nghiệm để đánh giá, so sánh kết quả.

1.7. Tóm tắt chương 1

Chương 1 đã trình bày tổng quan và cơ sở lý thuyết liên quan đến bài toán phân loại cảm xúc bình luận thương mại điện tử, bao gồm:

- Làm rõ khái niệm **phân loại cảm xúc (Sentiment Classification)**, vai trò của bài toán và ý nghĩa ứng dụng trong thương mại điện tử.
- Phân tích **đặc thù của dữ liệu bình luận thương mại điện tử tiếng Việt**, bao gồm cách diễn đạt, từ viết tắt, biểu tượng cảm xúc và các yếu tố ngôn ngữ không chuẩn.
- Trình bày **các ứng dụng và thách thức** trong bài toán phân loại cảm xúc văn bản.
- Giới thiệu **các tiêu chí đánh giá mô hình** thường được sử dụng trong phân loại văn bản như Accuracy, Precision, Recall và F1-score.
- Khảo sát **các hướng tiếp cận trong phân loại văn bản**, bao gồm các mô hình học máy truyền thống và các mô hình hiện đại dựa trên kiến trúc Transformer.
- Xác định **định hướng thực hiện của đề tài**, tập trung vào việc xây dựng và so sánh hai mô hình tiêu biểu gồm **TF-IDF kết hợp Logistic Regression** và **mô hình Transformer PhoBERT** cho bài toán phân loại cảm xúc bình luận thương mại điện tử tiếng Việt.

Những nội dung lý thuyết trong chương này là cơ sở để triển khai phần phương pháp nghiên cứu và xây dựng mô hình trong chương tiếp theo.

CHƯƠNG 2 : Phương pháp nghiên cứu và xây dựng mô hình

2.1. Thiết kế thực nghiệm cho bài toán phân loại cảm xúc

Trong nghiên cứu này, bài toán được thiết lập dưới dạng phân loại văn bản có giám sát, trong đó mỗi bình luận thương mại điện tử bằng tiếng Việt được gán vào một nhãn cảm xúc tương ứng. Trên cơ sở tập dữ liệu đã được chuẩn hóa và gán nhãn, đề tài xây dựng một quy trình thực nghiệm thống nhất để đánh giá và so sánh hiệu quả của hai mô hình đã lựa chọn.

Cụ thể, cùng một tập dữ liệu được sử dụng cho toàn bộ quá trình nghiên cứu; việc chia dữ liệu thành tập huấn luyện và tập kiểm tra được thực hiện nhất quán; các bước tiền xử lý được thiết kế phù hợp với đặc điểm đầu vào của từng mô hình; đồng thời hệ chỉ số đánh giá cũng được áp dụng thống nhất nhằm bảo đảm tính khách quan trong so sánh.

Trong khung thực nghiệm này, mô hình **TF-IDF kết hợp Logistic Regression** được sử dụng như mô hình cơ sở để thiết lập mốc tham chiếu ban đầu. Song song đó, mô hình **PhoBERT** được fine-tuning cho tác vụ phân loại chuỗi nhằm đánh giá khả năng khai thác ngữ cảnh sâu trên dữ liệu tiếng Việt. Kết quả thực nghiệm của hai mô hình sẽ được đối chiếu không chỉ ở chất lượng phân loại mà còn ở một số khía cạnh triển khai như thời gian huấn luyện, thời gian suy luận và mức độ phù hợp với điều kiện tài nguyên tính toán.

Trên cơ sở thiết kế này, các nội dung tiếp theo của chương sẽ lần lượt trình bày dữ liệu nghiên cứu, quy trình tiền xử lý, cấu hình mô hình, thiết lập huấn luyện và tiêu chí đánh giá để phục vụ cho phần thực nghiệm và phân tích kết quả.

2.2. Dữ liệu nghiên cứu

Dữ liệu nghiên cứu của đề tài là tập hợp các bình luận thương mại điện tử bằng tiếng Việt đã được gán nhãn cảm xúc. Các bình luận này có thể được thu thập từ các nền tảng thương mại điện tử hoặc từ các nguồn dữ liệu công khai phù hợp với mục tiêu nghiên cứu. Nội dung bình luận phản ánh cảm nhận của người dùng đối với sản phẩm, dịch vụ, chất lượng giao hàng, đóng gói, chăm sóc khách hàng hoặc trải nghiệm mua sắm nói chung.

Sau khi thu thập, dữ liệu được tổ chức theo dạng bảng gồm tối thiểu hai cột chính: cột nội dung bình luận (comment) và cột nhãn cảm xúc (label).

Trong quá trình chuẩn bị dữ liệu, nhóm tiến hành kiểm tra và làm sạch các mẫu không phù hợp như bình luận rỗng, bình luận trùng lặp, dữ liệu thiếu nhãn hoặc các mẫu không liên quan trực tiếp đến cảm xúc của người dùng. Sau đó, các nhãn cảm xúc được chuẩn hóa về một hệ thống thống nhất để phục vụ huấn luyện mô hình. Trường hợp dữ liệu ban đầu được gán theo số sao hoặc mức độ đánh giá khác nhau, cần chuyển đổi về các lớp cảm xúc mục tiêu theo quy tắc xác định trước.


Bảng 2.2.1. Tập dữ liệu và nhãn tương ứng

	Content	Label
0	Áo bao đẹp ạ!	POS
1	Tuyệt vời	POS
2	2day ao khong giong trong	NEG
3	Mùi thơm,bôi lên da mềm da	POS
4	Vải đẹp, dày dặn	POS
5	Hàng rất đẹp, rất chi là ưng ý	POS
6	Chất lượng sản phẩm tốt, date dài	POS
7	Ăn nói và thái độ phục vụ tốt	POS
8	Đóng gói sản phẩm chắc chắn	POS
9	tất sồn hết ca chưa dùng mà vay r	NEG
10	Shop phục vụ rất tốt	POS
11	Mặc thì cũng đc	NEU
....		

31455	Không đáng tiền	NEG
31456	Quần rất đẹp	POS
31457	Hàng đẹp đúng giá tiền	POS
31458	Chất vải khá ổn	POS
31459	áo rất ok nhé , vải mịn , len cao cổ này phối ...	POS

Ngoài ra, trước khi huấn luyện, nhóm cần thống kê mô tả dữ liệu để hiểu rõ quy mô tập dữ liệu, phân bố số lượng mẫu theo từng lớp cảm xúc, độ dài trung bình của bình luận, tỷ lệ dữ liệu lệch lớp và một số đặc trưng cơ bản khác. Những thống kê này không chỉ giúp mô tả dữ liệu nghiên cứu mà còn hỗ trợ giải thích kết quả thực nghiệm ở các phần sau. Các số liệu cụ thể nhóm thu được sau quá trình chuẩn bị và làm sạch dữ liệu như sau:


Hình 2.2.1. Quy mô dữ liệu, phân bố số lượng(từ lóng, emoji).



Hình 2.2.1 minh họa phân bố các nhãn cảm xúc trong tập dữ liệu nghiên cứu. Kết quả cho thấy số lượng bình luận tích cực chiếm tỷ lệ lớn nhất với 20.093 mẫu (63,9%), tiếp theo là các bình luận tiêu cực với 6.669 mẫu (21,2%) và cuối cùng là các bình luận trung lập với 4.698 mẫu (14,9%). Điều này cho thấy tập dữ liệu có sự lệch lớp nhất định, trong đó các phản hồi tích cực xuất hiện nhiều hơn so với các loại cảm xúc còn lại. Đây cũng là đặc


điểm phổ biến của dữ liệu đánh giá trên các nền tảng thương mại điện tử, nơi người dùng thường để lại phản hồi khi hài lòng với sản phẩm hoặc dịch vụ.

Hình 2.2.2. Độ dài trung bình bình luận, tỷ lệ dữ liệu lệch so với nhãn thật



Hình 2.2.2 thể hiện phân bố độ dài của các bình luận trong tập dữ liệu. Kết quả cho thấy phần lớn các bình luận có độ dài ngắn, chủ yếu tập trung trong khoảng từ 4 đến 15 từ. Đặc điểm này giúp quá trình huấn luyện mô hình hiệu quả hơn do giảm chi phí tính toán và hỗ trợ lựa chọn độ dài chuỗi đầu vào phù hợp cho mô hình PhoBERT.

Hình 2.2.3. Phân bố các chủ đề phổ biến trong bình luận thương mại điện tử



Hình 2.2.3. phân bố các chủ đề phổ biến trong tập bình luận thương mại điện tử. Kết quả cho thấy các chủ đề liên quan đến **chất lượng sản phẩm** và **dịch vụ của shop** xuất hiện nhiều nhất trong dữ liệu, với số lần nhắc đến lần lượt là 8.151 và 7.025. Bên cạnh đó, các yếu tố liên quan đến trải nghiệm mua hàng như **giao hàng nhanh** và **đóng gói chắc chắn** cũng xuất hiện với tần suất tương đối cao, trong khi các chủ đề liên quan đến **giá cả** được nhắc đến ít hơn.

Phân bố này cho thấy người dùng thường tập trung đánh giá chất lượng sản phẩm và trải nghiệm dịch vụ khi để lại bình luận, đồng thời cũng ảnh hưởng đến quá trình huấn luyện mô hình do các từ vựng thuộc những chủ đề phổ biến sẽ xuất hiện với tần suất cao hơn trong tập dữ liệu.

2.3. Tiền xử lý văn bản tiếng Việt cho bình luận TMĐT

Tiền xử lý dữ liệu là một bước quan trọng trong bài toán phân loại cảm xúc văn bản, đặc biệt với dữ liệu bình luận thương mại điện tử vốn có tính không chuẩn hóa cao. Mục tiêu của giai đoạn này là làm sạch dữ liệu, giảm nhiễu, chuẩn hóa đầu vào và tạo điều kiện thuận lợi cho quá trình trích xuất đặc trưng hoặc huấn luyện mô hình.

Các bước tiền xử lý đối với mô hình Baseline như sau quy trình thực hiện tuân theo sơ đồ ở Hình 4.


Hình 2.3.1. Quy trình tiền xử lý cho mô hình LogisticRegression



Đối với mô hình PhoBERT, quá trình tiền xử lý có một số khác biệt. Vì PhoBERT là mô hình tiền huấn luyện dành cho tiếng Việt và có bộ tokenizer riêng, văn bản đầu vào cần

được chuẩn bị theo định dạng phù hợp với tokenizer của mô hình. Trong trường hợp này, việc tiền xử lý thường được giữ ở mức vừa phải để tránh làm mất thông tin ngữ cảnh quan trọng. Nhóm chủ yếu thực hiện các bước làm sạch cơ bản và chuẩn hóa cần thiết trước khi đưa dữ liệu vào tokenizer của PhoBERT.

Hình 2.3.2. Quy trình tiền xử lý cho mô hình PhoBERT



Sau khi hoàn tất tiền xử lý, dữ liệu văn bản được chuyển sang dạng phù hợp cho từng mô hình. Với TF-IDF + Logistic Regression, đầu vào là tập văn bản đã chuẩn hóa và tách từ để xây dựng ma trận đặc trưng TF-IDF. Với PhoBERT, đầu vào là tập văn bản được tokenizer chuyển đổi thành các chuỗi token ID, attention mask và các thành phần cần thiết khác cho quá trình fine-tuning. Toàn bộ quy trình tiền xử lý được áp dụng thống nhất trên toàn bộ dữ liệu để đảm bảo tính nhất quán trong thực nghiệm.

2.4. Mô hình và cấu hình thực nghiệm

Trong nghiên cứu này, nhóm triển khai hai mô hình đại diện cho hai hướng tiếp cận khác nhau trong bài toán phân loại cảm xúc văn bản tiếng Việt. Mô hình thứ nhất là baseline truyền thống sử dụng TF-IDF kết hợp Logistic Regression. Mô hình thứ hai là PhoBERT được fine-tuning cho tác vụ sequence classification. Việc lựa chọn hai mô hình này nhằm so sánh giữa một phương pháp đơn giản, phổ biến và một phương pháp hiện đại dựa trên học sâu.

Cả hai mô hình đều được huấn luyện trên cùng tập dữ liệu và đánh giá bằng cùng hệ chỉ số nhằm đảm bảo tính công bằng trong so sánh. Bên cạnh hiệu quả dự đoán, nhóm cũng quan tâm đến thời gian huấn luyện, chi phí suy luận và mức độ phù hợp của từng mô hình với điều kiện triển khai thực tế.


2.4.1. TF-IDF kết hợp Logistic Regression

Mô hình baseline của đề tài được xây dựng theo pipeline gồm hai thành phần chính: biểu diễn văn bản bằng TF-IDF và phân loại bằng Logistic Regression.

Ở bước đầu tiên, tập văn bản sau khi tiền xử lý được chuyển thành ma trận đặc trưng TF-IDF. Mỗi văn bản được biểu diễn dưới dạng một vector số với kích thước tương ứng với số lượng đặc trưng được lựa chọn trong từ điển. Giá trị của từng phần tử trong vector phản ánh mức độ quan trọng của từ hoặc cụm từ trong văn bản đó so với toàn bộ tập dữ liệu.

Sau khi thu được các vector đặc trưng TF-IDF, mô hình Logistic Regression được sử dụng để thực hiện nhiệm vụ phân loại cảm xúc. Thuật toán Logistic Regression học các trọng số tương ứng với từng đặc trưng nhằm tối ưu khả năng phân biệt giữa các lớp cảm xúc khác nhau. Trong quá trình dự đoán, mô hình sẽ sử dụng các trọng số đã học để ước lượng xác suất của từng lớp và đưa ra nhãn phân loại cuối cùng cho mỗi văn bản.

Hình 2.4.1. Sơ đồ kiến trúc của mô hình TF-IDF kết hợp Logistic Regression



Bảng 2.4.1.1 Các tham số dùng để thử nghiệm cơ bản cho vectorizer và mô hình LR

Tham Số	Giá Trị
max_features	10000
ngram_range	(1,2)
max_iter	1000
min_df	5
max_df	0.8
sublinear_tf	True
stop_words	None
Class_weight	Balanced
random_state	42

Giải thích các tham số :

- **max_features**: Giới hạn số lượng từ vựng được sử dụng. Chỉ giữ lại 10.000 từ quan trọng nhất nhằm giảm kích thước vector và tránh nhiễu dữ liệu.
- **ngram_range**: Sử dụng cả **unigram (1 từ)** và **bigram (2 từ)** để mô hình có thể nắm bắt tốt hơn ngữ cảnh.
- **min_df** : Chỉ giữ lại các từ xuất hiện ít nhất 5 lần trong toàn bộ tập dữ liệu nhằm loại bỏ các từ hiếm.
- **max_df**: Loại bỏ các từ xuất hiện quá nhiều (trên 80% tài liệu) vì chúng thường ít mang thông tin phân loại.
- **sublinear_tf** : Áp dụng log scaling cho term frequency để giảm ảnh hưởng của các từ xuất hiện quá nhiều.
- **stop_words**: Không loại bỏ stopwords mặc định vì dữ liệu tiếng Việt thường cần xử lý stopwords riêng.
- **max_iter**: Xác định số vòng lặp tối đa của thuật toán **Logistic Regression** trong quá trình huấn luyện. Giá trị 1000 giúp đảm bảo mô hình có đủ số lần lặp để hội tụ.
- **class_weight**: Thiết lập trọng số cho các lớp trong quá trình huấn luyện. Giá trị **balanced** giúp tự động điều chỉnh trọng số dựa trên số lượng mẫu của từng lớp, nhằm giảm ảnh hưởng của hiện tượng **mất cân bằng dữ liệu**.
- **random_state**: Giá trị seed được sử dụng để đảm bảo quá trình khởi tạo và huấn luyện mô hình có thể tái lập kết quả khi chạy lại chương trình.

Mô hình TF-IDF kết hợp Logistic Regression được sử dụng như một baseline trong nghiên cứu nhằm tạo ra một mốc so sánh cho mô hình học sâu PhoBERT.


Nếu mô hình PhoBERT đạt kết quả tốt hơn baseline, điều này cho thấy ưu thế của phương pháp biểu diễn ngữ cảnh sâu (contextual embedding) trong việc xử lý bài toán phân tích cảm xúc. Ngược lại, nếu mô hình baseline cho kết quả tương đương trong khi chi phí tính toán thấp hơn, thì đây cũng là một giải pháp thực tiễn cho các hệ thống yêu cầu hiệu năng cao và tài nguyên tính toán hạn chế.

2.4.2. PhoBERT fine-tuning cho sequence classification

PhoBERT là mô hình ngôn ngữ tiền huấn luyện dành cho tiếng Việt, được xây dựng trên kiến trúc Transformer. Trong nghiên cứu này, nhóm sử dụng PhoBERT cho tác vụ phân loại chuỗi bằng cách fine-tuning mô hình trên tập dữ liệu bình luận đã gán nhãn cảm xúc.

Quy trình fine-tuning bắt đầu từ việc sử dụng tokenizer của PhoBERT để chuyển đổi văn bản đầu vào thành các chuỗi token phù hợp với mô hình. Mỗi câu hoặc bình luận sau đó được ánh xạ thành token IDs và attention masks. Tùy theo thiết lập thực nghiệm, dữ liệu có thể được padding hoặc truncation để đảm bảo độ dài đầu vào thống nhất trong quá trình huấn luyện.

Trên phần đầu ra ngữ cảnh của PhoBERT, nhóm gắn thêm một lớp phân loại ở phía trên để dự đoán nhãn cảm xúc. Trong quá trình fine-tuning, toàn bộ mô hình hoặc phần lớn tham số của mô hình sẽ được cập nhật dựa trên dữ liệu của bài toán. Cách tiếp cận này cho phép PhoBERT học lại một phần để thích nghi tốt hơn với miền dữ liệu bình luận thương mại điện tử.

Hình 2.4.2. Sơ đồ kiến trúc PhoBert

Một số tham số quan trọng trong quá trình huấn luyện PhoBERT bao gồm learning rate, batch size, số epoch, chiến lược tối ưu hóa, cơ chế lưu checkpoint và early stopping. Do mô hình Transformer có số lượng tham số lớn và nhạy với cấu hình huấn luyện, nhóm sẽ lựa chọn các thiết lập phù hợp với khả năng của môi trường thực nghiệm và quy mô dữ liệu.

Bảng 2.4.2.1 Các tham số dùng để thử nghiệm cơ bản cho vectorizer và mô hình PhoBert

Tham Số	Giá Trị
output_dir	./result
learning_rate	2e-5
per_device_train_batch_size	8
per_device_eval_batch_size	8
num_train_epochs	5
seed	42

logging_dir	./logs
logging_steps	50
eval_strategy	epoch
save_strategy	epoch

Giải thích các tham số

- **output_dir**: Thư mục dùng để lưu **mô hình sau khi huấn luyện**, checkpoint và các kết quả liên quan. Sau khi training xong, trọng số của mô hình sẽ được lưu tại thư mục này để có thể tải lại và sử dụng cho dự đoán.
- **learning_rate** : Tốc độ học của mô hình trong quá trình tối ưu. Giá trị $2e-5$ (0.00002) là mức phổ biến khi fine-tuning các mô hình Transformer như BERT hoặc PhoBERT. Learning rate quá lớn có thể làm mô hình không hội tụ, quá nhỏ sẽ khiến quá trình học rất chậm.
- **per_device_train_batch_size**: Số lượng mẫu dữ liệu được đưa vào mô hình mỗi lần cập nhật trọng số trong quá trình huấn luyện trên mỗi thiết bị (CPU/GPU). Batch size nhỏ giúp giảm yêu cầu bộ nhớ GPU nhưng có thể làm training lâu hơn.
- **per_device_eval_batch_size** : Số lượng mẫu được sử dụng mỗi lần đánh giá mô hình (evaluation) trên mỗi thiết bị. Tham số này thường có giá trị tương tự hoặc lớn hơn batch size huấn luyện.
- **num_train_epochs** : Số lần mô hình **duyệt qua toàn bộ tập dữ liệu huấn luyện**. Ví dụ 5 epochs nghĩa là toàn bộ dataset sẽ được dùng để huấn luyện mô hình 5 lần. Epoch quá lớn có thể gây overfitting.
- **seed** : Giá trị seed dùng để **cố định quá trình sinh số ngẫu nhiên** trong huấn luyện (khởi tạo trọng số, chia dữ liệu, shuffle...). Điều này giúp đảm bảo **kết quả có thể tái lập (reproducibility)** khi chạy lại thí nghiệm.
- **logging_dir** : Thư mục lưu log huấn luyện, bao gồm thông tin về loss, accuracy hoặc các metric trong quá trình training. Các log này có thể được sử dụng để theo dõi tiến trình học của mô hình hoặc hiển thị bằng TensorBoard.
- **logging_steps** : Xác định số bước huấn luyện (training steps) giữa hai lần ghi log trong quá trình training. Với giá trị 50, mô hình sẽ ghi lại thông tin huấn luyện như giá trị hàm mất mát (loss) sau mỗi 50 bước cập nhật trọng số.

- **eval_strategy** : Xác định chiến lược đánh giá mô hình trong quá trình huấn luyện. Khi đặt giá trị là "epoch", mô hình sẽ thực hiện đánh giá trên tập validation sau mỗi lần hoàn thành một epoch.
- **save_strategy** : Xác định chiến lược lưu mô hình trong quá trình huấn luyện. Khi đặt giá trị "epoch", mô hình sẽ tự động lưu lại checkpoint sau mỗi lần hoàn thành một epoch.

So với baseline, PhoBERT có ưu thế lớn ở khả năng biểu diễn ngữ cảnh sâu, từ đó kỳ vọng cải thiện chất lượng phân loại trong các trường hợp câu phức tạp, nhiều sắc thái hoặc có ngữ cảnh biểu đạt gián tiếp. Tuy nhiên, đổi lại, mô hình này đòi hỏi nhiều tài nguyên tính toán hơn và thời gian huấn luyện dài hơn. Đây là một trong những nội dung mà nghiên cứu sẽ phân tích và so sánh trong phần kết quả.

2.5. Thiết lập huấn luyện và tiêu chí đánh giá

Để đảm bảo quá trình so sánh giữa hai mô hình diễn ra công bằng, nghiên cứu sử dụng cùng một tập dữ liệu và cùng thiết lập thực nghiệm cho cả hai phương pháp. Sau khi hoàn tất bước tiền xử lý, dữ liệu được chia thành hai phần gồm tập huấn luyện (train set) và tập kiểm tra (test set). Trong nghiên cứu này, dữ liệu được chia theo tỉ lệ 80% cho tập huấn luyện và 20% cho tập kiểm tra. Tập huấn luyện được sử dụng để xây dựng mô hình, trong khi tập kiểm tra được dùng để đánh giá khả năng dự đoán trên các dữ liệu chưa từng xuất hiện trong quá trình huấn luyện.

Đối với mô hình TF-IDF kết hợp Logistic Regression, dữ liệu văn bản trong tập huấn luyện trước tiên được chuyển đổi thành ma trận đặc trưng TF-IDF. Các vector đặc trưng này sau đó được sử dụng để huấn luyện mô hình Logistic Regression nhằm học ranh giới phân lớp giữa các nhãn cảm xúc.

Đối với mô hình PhoBERT, dữ liệu văn bản được xử lý thông qua tokenizer của mô hình để chuyển thành các chuỗi token ID và attention mask. Mô hình PhoBERT sau đó được fine-tuning trên tập huấn luyện, trong đó các tham số của mô hình được cập nhật nhằm thích nghi với nhiệm vụ phân loại cảm xúc. Trong quá trình huấn luyện, mô hình có thể

được đánh giá định kỳ trên tập validation để theo dõi quá trình học và hạn chế hiện tượng overfitting.

Hiệu quả của các mô hình được đánh giá trên tập kiểm tra dựa trên các tiêu chí đã trình bày ở Mục 1.4. Ngoài ra, confusion matrix được sử dụng để hỗ trợ phân tích chi tiết các trường hợp dự đoán đúng và sai giữa các lớp cảm xúc.

Bên cạnh chất lượng phân loại, nghiên cứu cũng xem xét một số yếu tố về hiệu năng thực thi như thời gian huấn luyện, thời gian suy luận và mức độ sử dụng tài nguyên tính toán. Những yếu tố này giúp đánh giá khả năng áp dụng của từng mô hình trong các hệ thống thực tế.

2.6. Môi trường thực nghiệm

Toàn bộ quá trình thực nghiệm của đề tài được triển khai trên môi trường Google Colab với ngôn ngữ lập trình Python. Việc lựa chọn Google Colab giúp thuận tiện trong quá trình cài đặt thư viện, quản lý notebook và đặc biệt là tận dụng tài nguyên GPU khi huấn luyện các mô hình học sâu như Transformer. Đây là một môi trường phù hợp cho bài toán nghiên cứu ở quy mô đồ án chuyên ngành vì vừa linh hoạt vừa dễ sử dụng.

Đối với mô hình truyền thống TF-IDF kết hợp Logistic Regression, đề tài sử dụng các thư viện phổ biến trong hệ sinh thái Python như NumPy, Pandas và scikit-learn. Trong đó, Pandas được dùng để xử lý dữ liệu dạng bảng, NumPy hỗ trợ các phép toán trên mảng số học, còn scikit-learn cung cấp các công cụ để xây dựng vector TF-IDF, huấn luyện mô hình Logistic Regression và đánh giá kết quả.

Đối với mô hình PhoBERT, quá trình fine-tuning được triển khai bằng PyTorch kết hợp với thư viện Transformers. Thư viện Transformers cung cấp tokenizer và mô hình PhoBERT tiền huấn luyện, trong khi PyTorch hỗ trợ quá trình huấn luyện, tối ưu hóa tham số và xử lý dữ liệu tensor trong quá trình học.

Bảng 2.6.1. Cấu Hình Môi Trường Thực Nghiệm

Thành Phần	Cấu Hình
Nền tảng	Google Colab
GPU	NVIDIA Tesla T4
VRAM GPU	15 GB
RAM	12.7 GB
Python	3.12.12

2.7. Tóm tắt chương 2

Chương 2 đã trình bày phương pháp nghiên cứu và quy trình xây dựng mô hình cho bài toán phân loại cảm xúc bình luận thương mại điện tử tiếng Việt. Trước hết, chương đã mô tả rõ bài toán nghiên cứu, mục tiêu so sánh giữa hai hướng tiếp cận và quy trình nghiên cứu tổng quát. Sau đó, chương đã trình bày về dữ liệu nghiên cứu, cách tổ chức dữ liệu và định hướng chuẩn bị tập dữ liệu phục vụ thực nghiệm.

Tiếp theo, chương đã mô tả quy trình tiền xử lý văn bản tiếng Việt cho dữ liệu bình luận thương mại điện tử, bao gồm làm sạch, chuẩn hóa và chuyển đổi dữ liệu sang định dạng phù hợp cho từng mô hình. Hai mô hình được triển khai trong nghiên cứu gồm baseline truyền thống TF-IDF kết hợp Logistic Regression và mô hình Transformer PhoBERT fine-tuning cũng đã được trình bày cùng định hướng cấu hình thực nghiệm.

Cuối cùng, chương đã nêu các thiết lập huấn luyện, các chỉ số đánh giá chính và môi trường thực nghiệm sử dụng trong nghiên cứu. Những nội dung này là cơ sở để triển khai các thí nghiệm, trình bày kết quả và phân tích so sánh ở giai đoạn tiếp theo của đề tài.

Trong nghiên cứu này, dữ liệu văn bản được thực hiện tiền xử lý trước khi đưa vào quá trình huấn luyện nhằm giảm nhiễu và tăng tính nhất quán của tập dữ liệu đầu vào. Quy trình xử lý dữ liệu được áp dụng thống nhất cho cả hai mô hình Logistic Regression và mô hình PhoBERT, bao gồm các bước chuẩn hóa văn bản, chuyển đổi nhãn dữ liệu, loại bỏ dữ liệu thiếu và chia tập dữ liệu huấn luyện – kiểm tra.

Ngoài ra, trong quá trình thực nghiệm, nghiên cứu sử dụng cùng một giá trị seed cố định (seed = 42) cho các thư viện xử lý ngẫu nhiên như NumPy, PyTorch và Random nhằm đảm bảo tính tái lập của kết quả huấn luyện giữa các lần chạy mô hình.

```
def normalize_text(text):

    text = text.lower()

    slang_dict = {

        "khong": "không", "ko": "không", "k": "không", "hok": "không",

        "giong": "giống", "sp": "sản phẩm", "mik": "mình", "dc": "được", "đc":

"được"

    }

    for k, v in slang_dict.items():

        text = text.replace(k, v)

    text = re.sub(r'(\.){1+}', r'\1', text) # bỏ ký tự lặp

    text = re.sub(r'[\^w\s]', ' ', text) # bỏ ký tự đặc biệt
```

```

text = re.sub(r'\s+', ' ', text).strip()

return text

df["content"] = df["content"].apply(normalize_text)

```

Trong bước đầu tiên của quá trình huấn luyện mô hình, dữ liệu văn bản được chuẩn hóa nhằm giảm nhiễu và tăng tính nhất quán cho tập dữ liệu đầu vào. Cụ thể, toàn bộ văn bản được chuyển về chữ thường để tránh sự khác biệt giữa chữ hoa và chữ thường. Sau đó, các từ lóng phổ biến trong tiếng Việt như “ko”, “k”, “mik”, “sp”, “dc” được thay thế bằng dạng chuẩn tương ứng như “không”, “mình”, “sản phẩm”, “được”. Ngoài ra, các ký tự lặp nhiều lần như “đẹpppp” cũng được rút gọn thành “đẹp”, đồng thời loại bỏ các ký tự đặc biệt và chuẩn hóa khoảng trắng. Việc chuẩn hóa này giúp mô hình học được đặc trưng ngôn ngữ tốt hơn và cải thiện hiệu quả phân loại.

Các thao tác chuẩn hóa bao gồm:

- Chuyển toàn bộ văn bản về chữ thường
- Chuẩn hóa các từ viết tắt phổ biến trong tiếng Việt (ví dụ: “ko”, “k”, “dc”, “sp”)
- Loại bỏ các ký tự lặp nhiều lần (ví dụ: “đẹpppp” → “đẹp”)
- Loại bỏ các ký tự đặc biệt không cần thiết
- Chuẩn hóa khoảng trắng giữa các từ

Sau bước này, dữ liệu văn bản trở nên đồng nhất hơn và giúp mô hình học được đặc trưng ngôn ngữ hiệu quả hơn.

Bước 2: Chuyển đổi nhãn dữ liệu

```

label_map = {"NEG": 0, "NEU": 1, "POS": 2}

df["label"] = df["label"].map(label_map)

```

Trong tập dữ liệu ban đầu, nhãn cảm xúc được biểu diễn dưới dạng chuỗi ký tự gồm ba lớp:

- NEG (tiêu cực)
- NEU (trung tính)
- POS (tích cực)

Tuy nhiên, các mô hình học máy và học sâu không thể xử lý trực tiếp dữ liệu dạng chuỗi nên cần chuyển đổi các nhãn này sang dạng số nguyên tương ứng như sau:

- NEG $\rightarrow$ 0
- NEU $\rightarrow$ 1
- POS $\rightarrow$ 2

Quá trình này được gọi là **Label Encoding**, giúp mô hình có thể thực hiện các phép tính toán trong quá trình huấn luyện.

Bước 3: Chia tập dữ liệu

```
X_train, X_test, y_train, y_test = train_test_split(
    df["content"], df["label"], test_size=0.2, random_state=seed
)
```

Sau khi hoàn tất bước tiền xử lý, tập dữ liệu được chia thành hai phần:

- 80% dữ liệu dùng để huấn luyện mô hình
- 20% dữ liệu dùng để kiểm tra mô hình

Việc chia dữ liệu được thực hiện bằng phương pháp chia ngẫu nhiên nhằm đảm bảo tính đại diện của dữ liệu trong cả hai tập.

Tập dữ liệu này được sử dụng chung cho cả hai mô hình Logistic Regression và PhoBERT, đảm bảo điều kiện so sánh hiệu năng giữa hai mô hình là tương đương.

Bước 4: Cố định seed

```
seed = 42

torch.manual_seed(seed)
```

```
np.random.seed(seed)

random.seed(seed)
```

Trong quá trình thực nghiệm, nghiên cứu sử dụng seed cố định bằng giá trị 42 cho các thư viện:

- NumPy
- PyTorch
- Random

Việc cố định seed giúp đảm bảo rằng quá trình chia dữ liệu và huấn luyện mô hình có thể được tái lập giữa các lần chạy khác nhau, đồng thời đảm bảo tính nhất quán khi so sánh kết quả giữa hai mô hình Logistic Regression và PhoBERT.

3.1.1. Quy trình triển khai mô hình TF-IDF kết hợp Logistic Regression

Sau khi hoàn tất quá trình tiền xử lý dữ liệu chung, mô hình Logistic Regression được sử dụng để thực hiện bài toán phân loại cảm xúc văn bản. Đây là một thuật toán học máy có giám sát phổ biến trong các bài toán phân loại văn bản nhờ ưu điểm đơn giản, hiệu quả và tốc độ huấn luyện nhanh.

Do Logistic Regression không thể xử lý trực tiếp dữ liệu văn bản dạng chuỗi nên dữ liệu đầu vào cần được chuyển đổi sang dạng vector số thông qua phương pháp TF-IDF (Term Frequency – Inverse Document Frequency).

Bước 1: Vector hóa văn bản bằng TF-IDF

```
vectorizer = TfidfVectorizer(

    max_features=10000,

    ngram_range=(1,2),

    min_df=5,

    max_df=0.85,

    sublinear_tf=True
```


)

Trong bước này, dữ liệu văn bản sau khi được chuẩn hóa sẽ được chuyển đổi từ dạng chuỗi ký tự sang dạng vector số để mô hình học máy có thể xử lý. Do các mô hình học máy không thể làm việc trực tiếp với dữ liệu văn bản thô, phương pháp TF-IDF được sử dụng để biểu diễn mỗi câu thành một vector số thể hiện mức độ quan trọng của các từ trong câu so với toàn bộ tập dữ liệu. Nhờ đó, mô hình có thể học được các đặc trưng quan trọng phục vụ cho bài toán phân loại cảm xúc.

TF-IDF giúp xác định mức độ quan trọng của một từ trong văn bản dựa trên:

- Tần suất xuất hiện của từ trong văn bản (Term Frequency)
- Mức độ phổ biến của từ trong toàn bộ tập dữ liệu (Inverse Document Frequency)

Nhờ đó:

- Các từ quan trọng trong câu sẽ có trọng số cao
- Các từ phổ biến nhưng ít mang ý nghĩa phân biệt sẽ có trọng số thấp

Sau bước này, mỗi câu văn bản được biểu diễn thành một vector đặc trưng số làm đầu vào cho mô hình Logistic Regression.

```
X_train_tfidf = vectorizer.fit_transform(X_train)
```

```
X_test_tfidf = vectorizer.transform(X_test)
```

Sử dụng để huấn luyện bộ biến đổi TF-IDF trên tập dữ liệu huấn luyện. Trong đó, hàm **fit()** giúp xây dựng từ điển đặc trưng bằng cách xác định các từ quan trọng nhất xuất hiện trong tập dữ liệu huấn luyện, còn hàm **transform()** chuyển đổi các câu trong tập huấn luyện thành vector số tương ứng với từ điển đặc trưng vừa tạo. Kết quả thu được là một ma trận dạng sparse matrix (ma trận thưa), trong đó mỗi hàng biểu diễn một câu và mỗi cột biểu diễn một đặc trưng từ vựng.

Ví dụ: “ Sản phẩm rất tốt ” sau khi vector hóa có thể trở thành [0.12, 0.45, 0.33, 0.08]

Bước 3: Huấn luyện Logistic Regression

```
model = LogisticRegression(max_iter=1000)
model.fit(X_train_tfidf, y_train)
```

Sau khi dữ liệu văn bản đã được chuyển đổi sang dạng vector số bằng phương pháp TF-IDF, mô hình Logistic Regression được sử dụng để thực hiện quá trình huấn luyện phân loại cảm xúc văn bản. Trong bước này, mô hình học mối quan hệ giữa vector đặc trưng đầu vào và nhãn cảm xúc tương ứng thông qua việc tối ưu các tham số trọng số nhằm giảm sai số dự đoán.

Cụ thể, mỗi câu sau khi vector hóa sẽ được biểu diễn dưới dạng một vector đặc trưng x , trong đó mỗi phần tử của vector thể hiện mức độ quan trọng của một từ hoặc cụm từ trong câu theo phương pháp TF-IDF. Sau đó, mô hình thực hiện phép nhân tuyến tính giữa vector đặc trưng x và vector trọng số w_k của từng lớp cảm xúc để tính toán giá trị đầu ra tương ứng với mỗi lớp.

Đối với bài toán phân loại đa lớp gồm ba lớp NEG, NEU và POS, Logistic Regression sử dụng hàm Softmax để chuyển các giá trị đầu ra thành xác suất dự đoán cho từng lớp theo công thức:

$$p(y = k|x) = \frac{e^{w_k^T x}}{\sum_{j=1}^K e^{w_j^T x}}$$

Trong đó x là vector đặc trưng TF-IDF của câu, w_k là vector trọng số của lớp thứ k , và K là tổng số lớp cần phân loại. Giá trị xác suất lớn nhất sẽ được chọn làm nhãn dự đoán của mô hình.

Trong quá trình huấn luyện, mô hình sử dụng hàm mất mát Cross-Entropy để đo lường mức độ sai lệch giữa nhãn dự đoán và nhãn thực tế. Hàm mất mát được xác định theo công thức:

$$Loss = - \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log(p_{ik})$$

Trong đó y_{ik} là nhãn thực tế và p_{ik} là xác suất dự đoán tương ứng của lớp thứ k . Giá trị hàm mất mát càng nhỏ thì kết quả dự đoán của mô hình càng gần với nhãn thực tế.

Sau khi tính toán giá trị hàm mất mát, mô hình tiến hành tính gradient của hàm mất mát theo các tham số trọng số để xác định mức độ ảnh hưởng của từng tham số đến sai số dự đoán. Dựa trên giá trị gradient này, các trọng số của mô hình được cập nhật thông qua thuật toán tối ưu hóa (solver) như LBFGS (Limited memory Broyden Fletcher Goldfarb Shanno) nhằm giảm sai số dự đoán và cải thiện độ chính xác của mô hình qua nhiều vòng lặp huấn luyện. Quá trình cập nhật trọng số được thực hiện lặp lại cho đến khi mô hình đạt được hiệu suất tối ưu trên tập dữ liệu huấn luyện.

Quá trình cập nhật trọng số được thực hiện lặp lại cho đến khi mô hình đạt được hiệu suất tối ưu hoặc đạt số vòng lặp tối đa được thiết lập trong tham số `max_iter=1000`

3.1.2. Quy trình triển khai mô hình PhoBERT

Sau khi hoàn tất quá trình tiền xử lý dữ liệu chung, mô hình PhoBERT được sử dụng để thực hiện bài toán phân loại cảm xúc văn bản tiếng Việt. PhoBERT là mô hình ngôn ngữ tiền huấn luyện dựa trên kiến trúc Transformer, được phát triển chuyên biệt cho tiếng Việt và đạt hiệu quả cao trong nhiều bài toán xử lý ngôn ngữ tự nhiên.

Khác với mô hình Logistic Regression sử dụng phương pháp TF-IDF để biểu diễn dữ liệu, mô hình PhoBERT có khả năng tự động học đặc trưng ngữ nghĩa của văn bản thông qua cơ chế attention trong kiến trúc Transformer. Trong nghiên cứu này, mô hình PhoBERT được fine-tuning trên tập dữ liệu phân loại cảm xúc nhằm tối ưu hiệu năng dự đoán.

Bước 1: Tokenization và xây dựng tập dữ liệu huấn luyện

Dữ liệu văn bản tiếp tục được xử lý thông qua **tokenizer của mô hình PhoBERT** nhằm chuyển đổi văn bản từ dạng chuỗi ký tự sang dạng vector số để mô hình có thể xử lý.

Do các mô hình học sâu không thể làm việc trực tiếp với dữ liệu văn bản thô, quá trình **tokenization** được thực hiện để biến đổi mỗi câu thành chuỗi các token, sau đó ánh xạ các token này thành các chỉ số tương ứng trong từ điển của mô hình (*token IDs*).

Sau khi thực hiện tokenization, mỗi câu dữ liệu sẽ được biểu diễn thông qua hai thành phần chính:

- **input_ids**: là danh sách các chỉ số biểu diễn các token tương ứng với từng từ trong câu dựa trên từ điển của mô hình PhoBERT
- **attention_mask**: là vector nhị phân dùng để xác định vị trí token thực và token padding nhằm đảm bảo các câu có cùng độ dài khi đưa vào mô hình

Trong đó:

- giá trị **1** biểu thị token thực
- giá trị **0** biểu thị token padding

Hai thành phần này giúp mô hình xác định chính xác những vị trí thông tin cần xử lý và những vị trí cần bỏ qua trong quá trình huấn luyện.

Sau đó, dữ liệu được chuyển sang định dạng Dataset của thư viện HuggingFace để phục vụ cho quá trình huấn luyện:

```
train_dataset = Dataset.from_dict({
    "input_ids": train_encodings["input_ids"],
    "attention_mask": train_encodings["attention_mask"],
    "labels": train_labels.tolist()
})

val_dataset = Dataset.from_dict({
    "input_ids": val_encodings["input_ids"],
    "attention_mask": val_encodings["attention_mask"],
    "labels": val_labels.tolist()
})
```

Bước 2: Thiết lập tham số

```
training_args = TrainingArguments(  
    output_dir="./results",  
    learning_rate=2e-5,  
    per_device_train_batch_size=8,  
    per_device_eval_batch_size=8,  
    num_train_epochs=3,  
    seed=42,  
    logging_dir="./logs"  
)
```

Bước 3: Khởi tạo mô hình PhoBert


```
model = AutoModelForSequenceClassification.from_pretrained(  
    "vinai/phobert-base",  
    num_labels=3  
)
```

Trong nghiên cứu này, mô hình **PhoBERT-base** (*vinai/phobert-base*) được sử dụng làm mô hình nền cho bài toán phân loại cảm xúc tiếng Việt. PhoBERT là một mô hình ngôn ngữ tiền huấn luyện (pretrained language model) dựa trên kiến trúc Transformer, được huấn luyện trước trên một tập dữ liệu tiếng Việt có quy mô lớn, bao gồm nhiều nguồn văn bản khác nhau như báo chí, Wikipedia và dữ liệu web. Nhờ đó, mô hình có khả năng học được các đặc trưng ngữ nghĩa và ngữ cảnh phong phú của tiếng Việt.

Sau khi khởi tạo mô hình PhoBERT-base, mô hình tiếp tục được **fine-tune** trên tập dữ liệu của bài toán phân loại cảm xúc gồm ba lớp: *NEG* (tiêu cực), *NEU* (trung tính) và *POS* (tích

cực). Quá trình fine-tune giúp điều chỉnh lại các tham số của mô hình đã được huấn luyện trước để phù hợp hơn với đặc trưng của tập dữ liệu cụ thể trong bài toán, từ đó nâng cao hiệu quả phân loại cảm xúc. Việc sử dụng mô hình PhoBERT kết hợp với quá trình fine-tune giúp tận dụng được tri thức ngôn ngữ đã học trước đó, đồng thời cải thiện khả năng tổng quát hóa và độ chính xác của mô hình trên dữ liệu tiếng Việt.

Hình 3.1.2.1 Fine-Tuning mô hình PhoBert



Bước 4: Huấn luyện

```

trainer = Trainer(
    model=model,
    args=training_args,
    train_dataset=train_dataset,
    eval_dataset=val_dataset,
    compute_metrics=compute_metrics
)

trainer.train()

```

- **model:** là mô hình PhoBERT đã được khởi tạo cho bài toán phân loại cảm xúc

- **args**: chứa các tham số huấn luyện đã thiết lập trước đó
- **train_dataset**: tập dữ liệu dùng để huấn luyện mô hình
- **eval_dataset**: tập dữ liệu dùng để đánh giá mô hình sau mỗi epoch
- **compute_metrics**: hàm dùng để tính các chỉ số đánh giá như Accuracy và F1-score

Trong quá trình huấn luyện mô hình PhoBERT cho bài toán phân loại cảm xúc văn bản tiếng Việt, thư viện Transformers tự động thực hiện quy trình tối ưu mô hình thông qua các bước gồm: lan truyền thuận (*forward propagation*), tính toán hàm mất mát (*loss function*), lan truyền ngược (*backpropagation*) và cập nhật trọng số bằng thuật toán tối ưu AdamW. Quá trình này được lặp lại nhiều lần qua các epoch nhằm giúp mô hình học được các đặc trưng phù hợp từ dữ liệu huấn luyện.

Forward Propagation

Trong bước lan truyền thuận, dữ liệu đầu vào gồm hai thành phần chính:

- `input_ids`
- `attention_mask`

được đưa vào mô hình PhoBERT để trích xuất đặc trưng ngữ nghĩa thông qua các tầng **Transformer Encoder**.

Sau quá trình xử lý, mô hình tạo ra vector đầu ra gọi là logits, biểu diễn điểm số dự đoán tương ứng với từng lớp cảm xúc: NEG, NEU và POS.

Vector logits được tính theo biểu thức: $z = Wx + bz$

Trong đó:

- `x`: vector đặc trưng đầu ra từ PhoBERT
- `W`: ma trận trọng số của lớp phân loại
- `b`: vector bias
- `z`: vector logits của mô hình

Sau đó, logits được đưa qua hàm Softmax để chuyển thành xác suất dự đoán cho từng lớp:

$$P(y = K|x) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}$$

Trong đó:

- z_k là giá trị logits của lớp thứ k
- $K=3$ là số lớp phân loại (NEG, NEU, POS)

Lớp có xác suất lớn nhất sẽ được chọn làm nhãn dự đoán của mô hình.

Tính hàm mất mát

Sau bước lan truyền thuận (*forward propagation*), mô hình sử dụng hàm mất mát **CrossEntropyLoss** để đo lường mức độ sai lệch giữa kết quả dự đoán của mô hình và nhãn thực tế của dữ liệu. Hàm mất mát đóng vai trò quan trọng trong quá trình huấn luyện vì nó cung cấp thông tin để mô hình biết mức độ dự đoán đúng hay sai, từ đó điều chỉnh trọng số phù hợp thông qua quá trình lan truyền ngược.

Trong bài toán phân loại cảm xúc văn bản gồm nhiều lớp (ví dụ: tích cực, tiêu cực, trung tính), hàm mất mát CrossEntropyLoss được xác định theo công thức:

Hàm mất mát được xác định theo công thức:

$$Loss = - \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log(p_{ik})$$

Trong đó y_{ik} là nhãn thực tế và p_{ik} là xác suất dự đoán tương ứng của lớp thứ k . Giá trị hàm mất mát càng nhỏ thì kết quả dự đoán của mô hình càng gần với nhãn thực tế.

Giá trị hàm mất mát càng nhỏ cho thấy mô hình dự đoán càng chính xác.

Backpropagation

Sau khi tính được giá trị hàm mất mát (*loss function*), mô hình thực hiện quá trình lan truyền ngược (*backpropagation*) nhằm tính gradient của hàm mất mát theo các tham số của mô hình. Gradient thể hiện mức độ ảnh hưởng của từng tham số đến sai số dự đoán, từ đó

giúp mô hình biết cần điều chỉnh trọng số theo hướng nào để giảm giá trị hàm mất mát trong các bước huấn luyện tiếp theo.

Gradient của hàm mất mát theo trọng số được xác định theo biểu thức:

Gradient được xác định theo biểu thức: $\frac{\partial L}{\partial w}$

Trong quá trình lan truyền ngược, gradient được truyền từ lớp đầu ra trở về các lớp phía trước của mô hình thông qua quy tắc đạo hàm chuỗi (*chain rule*). Nhờ đó, mô hình xác định được mức độ ảnh hưởng của từng tham số đến kết quả dự đoán và điều chỉnh chúng phù hợp trong bước cập nhật trọng số tiếp theo.

Quá trình này được thực hiện lặp lại sau mỗi lần tính toán hàm mất mát trong suốt quá trình huấn luyện, giúp mô hình từng bước giảm sai số dự đoán và nâng cao độ chính xác phân loại trên tập dữ liệu huấn luyện.

Cập nhật trọng số bằng thuật toán AdamW

Sau khi tính được gradient của hàm mất mát thông qua quá trình lan truyền ngược (*backpropagation*), các tham số của mô hình được cập nhật bằng thuật toán tối ưu **AdamW** nhằm điều chỉnh trọng số theo hướng làm giảm sai số dự đoán. Việc cập nhật trọng số được thực hiện theo công thức:

Quy tắc cập nhật trọng số được thực hiện theo công thức:

$$W_{t+1} = W_t - n\Delta L$$

Trong đó:

- W_t là trọng số tại bước lặp thứ t
- n là learning rate
- ΔL là vector gradient đã được hiệu chỉnh theo thuật toán AdamW

Công thức trên cho thấy trọng số mới được điều chỉnh dựa trên gradient đã tính toán trước đó. Nếu gradient lớn, trọng số sẽ được điều chỉnh nhiều hơn; nếu gradient nhỏ, mức điều chỉnh sẽ ít hơn. Nhờ đó, mô hình từng bước tiến gần hơn đến giá trị trọng số tối ưu giúp giảm sai số dự đoán.

Trong nghiên cứu này, thuật toán tối ưu được sử dụng là **AdamW**, một phiên bản cải tiến của thuật toán Adam thường được áp dụng trong các mô hình Transformer như PhoBERT. AdamW có khả năng tự động điều chỉnh tốc độ học cho từng tham số dựa trên lịch sử gradient trong các bước huấn luyện trước đó, giúp quá trình hội tụ diễn ra nhanh hơn và ổn định hơn so với các phương pháp tối ưu truyền thống.

Ngoài ra, AdamW còn sử dụng cơ chế **weight decay** để hạn chế hiện tượng quá khớp (*overfitting*), được biểu diễn theo công thức:

$$W = W - \eta(\Delta L - \lambda w)$$

Trong đó:

- λ là hệ số weight decay

Cơ chế này giúp giảm giá trị của các trọng số không cần thiết trong quá trình huấn luyện, từ đó làm cho mô hình học được các đặc trưng quan trọng hơn và nâng cao khả năng tổng quát hóa khi áp dụng trên dữ liệu mới chưa xuất hiện trong tập huấn luyện. Nhờ vậy, mô hình PhoBERT có thể đạt hiệu quả phân loại tốt và ổn định hơn trong bài toán phân loại cảm xúc văn bản tiếng Việt.

Đánh giá mô hình theo từng epoch

Quá trình huấn luyện được thực hiện lặp lại qua nhiều epoch, trong đó mỗi epoch tương ứng với một lần mô hình học toàn bộ tập dữ liệu huấn luyện.

Sau mỗi epoch, mô hình được đánh giá trên tập validation nhằm:

- Theo dõi sự thay đổi của giá trị loss
- Đánh giá độ chính xác phân loại
- Kiểm soát hiện tượng overfitting

Việc đánh giá định kỳ giúp đảm bảo khả năng tổng quát hóa của mô hình trên dữ liệu chưa từng xuất hiện trong quá trình huấn luyện và làm cơ sở lựa chọn mô hình tối ưu cho bài toán phân loại cảm xúc văn bản tiếng Việt.

3.1.3. Ghi chú cài đặt, tham số và đầu ra huấn luyện

Sau khi trình bày quy trình triển khai mô hình TF-IDF kết hợp Logistic Regression ở Mục 3.1.1 và quy trình triển khai mô hình PhoBERT ở Mục 3.1.2, mục này tập trung làm rõ một số ghi chú kỹ thuật liên quan đến quá trình cài đặt, lựa chọn tham số và cách diễn giải đầu ra huấn luyện của từng mô hình. Việc bổ sung các ghi chú này giúp quá trình thực nghiệm được trình bày nhất quán, dễ tái lập và thuận lợi hơn trong việc đối chiếu kết quả giữa hai hướng tiếp cận.

Về mặt cài đặt, cả hai mô hình đều được triển khai trong môi trường Python trên Google Colab với cùng tập dữ liệu đã được tiền xử lý và cùng giá trị seed cố định nhằm đảm bảo tính tái lập của thí nghiệm. Tuy nhiên, do bản chất hai mô hình khác nhau nên thư viện và cách tổ chức pipeline triển khai cũng có sự khác biệt. Đối với mô hình TF-IDF kết hợp Logistic Regression, nhóm sử dụng chủ yếu các thư viện Pandas, NumPy và scikit-learn để thực hiện các bước vector hóa văn bản, huấn luyện mô hình và đánh giá kết quả. Trong khi đó, mô hình PhoBERT được triển khai bằng PyTorch kết hợp với thư viện Transformers và Datasets của HuggingFace để xử lý tokenizer, xây dựng tập dữ liệu huấn luyện và fine-tuning mô hình ngôn ngữ tiền huấn luyện. Sự khác biệt này cho thấy mô hình truyền thống có quy trình triển khai đơn giản hơn, trong khi mô hình PhoBERT yêu cầu pipeline xử lý phức tạp hơn và phụ thuộc nhiều hơn vào tài nguyên tính toán.

Về mặt tham số, đối với mô hình TF-IDF kết hợp Logistic Regression, các tham số quan trọng ảnh hưởng trực tiếp đến chất lượng đặc trưng và khả năng phân loại gồm số lượng đặc trưng cực đại `max_features`, khoảng n-gram `ngram_range`, ngưỡng xuất hiện tối thiểu `min_df`, ngưỡng loại bỏ từ phổ biến `max_df`, phép chuẩn hóa tần suất `sublinear_tf` và số vòng lặp tối đa `max_iter`. Các tham số này quyết định cách văn bản được biểu diễn dưới dạng vector TF-IDF, từ đó ảnh hưởng trực tiếp đến hiệu quả học của mô hình Logistic Regression. Trong thực nghiệm, việc lựa chọn unigram và bigram giúp mô hình không chỉ học các từ đơn lẻ mà còn nắm bắt được một số cụm từ ngắn mang ý nghĩa cảm xúc như “rất tốt”, “không đáng”, “giao nhanh” hoặc “khá ổn”. Đồng thời, việc giới hạn số lượng đặc trưng và loại bỏ các từ quá hiếm hoặc quá phổ biến giúp giảm nhiễu và làm cho mô hình ổn định hơn trong quá trình huấn luyện.

Đối với mô hình PhoBERT, các tham số cần quan tâm không chỉ nằm ở mức mô hình mà còn nằm ở quá trình fine-tuning. Các tham số như `learning_rate`, `batch_size`,

`num_train_epochs`, `seed`, thư mục lưu kết quả `output_dir` và thư mục log `logging_dir` có vai trò quan trọng trong việc kiểm soát tốc độ hội tụ, mức sử dụng bộ nhớ và khả năng lưu vết quá trình huấn luyện. So với Logistic Regression, mô hình PhoBERT nhạy hơn với cấu hình tham số; nếu `learning rate` quá lớn, mô hình có thể dao động và khó hội tụ, trong khi nếu `learning rate` quá nhỏ thì thời gian huấn luyện kéo dài và hiệu quả cải thiện chậm. Tương tự, `batch size` nhỏ giúp phù hợp với giới hạn bộ nhớ GPU nhưng có thể làm thời gian huấn luyện lâu hơn. Do đó, việc lựa chọn tham số cho PhoBERT cần cân bằng giữa chất lượng mô hình và khả năng đáp ứng của môi trường thực nghiệm.

Một điểm cần lưu ý là mặc dù cả hai mô hình đều được huấn luyện trên cùng tập dữ liệu đầu vào, nhưng đầu ra huấn luyện của hai mô hình có hình thức thể hiện khác nhau. Với mô hình TF-IDF kết hợp Logistic Regression, đầu ra chủ yếu bao gồm mô hình đã được huấn luyện, các nhãn dự đoán trên tập kiểm tra, ma trận nhầm lẫn và các chỉ số đánh giá như Accuracy, Precision, Recall và F1-score. Quá trình huấn luyện của Logistic Regression thường không tạo ra log chi tiết theo từng epoch mà tập trung vào kết quả cuối cùng sau khi tối ưu xong các trọng số. Vì vậy, việc theo dõi mô hình này chủ yếu dựa trên chất lượng đầu ra cuối cùng và thời gian huấn luyện tổng thể.

Ngược lại, đối với mô hình PhoBERT, đầu ra huấn luyện phong phú hơn do quá trình fine-tuning diễn ra qua nhiều epoch. Trong quá trình này, mô hình có thể sinh ra các thông tin như training loss, evaluation loss, accuracy, F1-score theo từng giai đoạn huấn luyện, cùng với checkpoint lưu trọng số mô hình tại các thời điểm khác nhau. Các log này cho phép theo dõi sát hơn tiến trình hội tụ của mô hình, đánh giá xu hướng cải thiện hiệu năng qua từng epoch và phát hiện sớm dấu hiệu quá khớp nếu chất lượng trên tập huấn luyện tiếp tục tăng trong khi chất lượng trên tập validation không còn cải thiện. Vì vậy, khác với Logistic Regression, đầu ra huấn luyện của PhoBERT không chỉ có ý nghĩa ở kết quả cuối cùng mà còn có giá trị trong việc phân tích động thái học của mô hình trong suốt quá trình fine-tuning.

Từ hai quy trình triển khai đã trình bày ở các mục trước, có thể thấy rằng đầu ra huấn luyện của mô hình TF-IDF kết hợp Logistic Regression phù hợp với cách đánh giá nhanh, trực tiếp và chi phí thấp, trong khi đầu ra của mô hình PhoBERT cho phép quan sát sâu hơn quá trình học nhưng đi kèm với độ phức tạp cài đặt và thời gian huấn luyện lớn hơn. Do đó, trong quá trình phân tích kết quả ở các mục tiếp theo, nghiên cứu không chỉ xem xét các chỉ số đánh giá cuối cùng mà còn lưu ý đến đặc điểm sinh log, khả năng lưu mô hình

và mức độ thuận tiện trong theo dõi huấn luyện của từng phương pháp. Đây cũng là cơ sở quan trọng để thảo luận sâu hơn về hiệu năng, khả năng triển khai và mức độ phù hợp của hai mô hình trong bài toán phân loại cảm xúc bình luận thương mại điện tử tiếng Việt.

Bảng 3.1.3.1. Ghi chú cài đặt, tham số và đầu ra huấn luyện của hai mô hình

Nội dung	TF-IDF + Logistic Regression	PhoBERT
Thư viện chính	scikit-learn, Pandas, NumPy	PyTorch, Transformers, Datasets
Dạng đầu vào	Vector TF-IDF	input_ids, attention_mask
Tham số nổi bật	max_features, ngram_range, max_iter	learning_rate, batch_size, epoch
Log huấn luyện	Ít, chủ yếu kết quả cuối	Có log theo epoch
Đầu ra chính	Nhãn dự đoán, metric, confusion matrix	loss, metric, checkpoint, confusion matrix
Độ phức tạp triển khai	Thấp	Cao
Yêu cầu tài nguyên	Thấp	Cao

3.2. Kết quả thực nghiệm của mô hình TF-IDF kết hợp Logistic Regression

3.2.1. Kết quả huấn luyện và đánh giá tổng thể

Mô hình TF-IDF kết hợp Logistic Regression được sử dụng làm mô hình baseline cho bài toán phân loại cảm xúc văn bản với ba nhãn NEG, NEU và POS. Sau khi huấn luyện trên tập dữ liệu huấn luyện, mô hình được đánh giá trên tập dữ liệu kiểm tra nhằm đo lường hiệu suất phân loại tổng thể.

Kết quả thực nghiệm cho thấy mô hình đạt **độ chính xác (Accuracy) 78.55%** và **F1-score tổng thể 0.759**. Bên cạnh đó, giá trị **macro average đạt 0.63** và **weighted average đạt**

0.76, cho thấy mô hình có khả năng phân loại ở mức tương đối tốt trên tập dữ liệu kiểm tra.

Bảng 3.2.1.1. Kết quả đánh giá tổng thể của mô hình TF-IDF kết hợp Logistic Regression

Lớp	Precision	Recall	F1-Score	Support
NEG	0.72	0.77	0.74	1353
NEU	0.45	0.19	0.27	987
POS	0.84	0.94	0.89	3948
accuracy	0.78	0.85	0.79	6288
marco avg	0.67	0.63	0.63	6288

Ngoài ra, giá trị macro average F1-score đạt 0.63 và weighted average F1-score đạt 0.76, cho thấy hiệu suất tổng thể của mô hình ở mức khá tốt trên tập dữ liệu kiểm tra. Sự chênh lệch giữa hai giá trị này phản ánh sự mất cân bằng giữa các lớp dữ liệu, trong đó lớp POS chiếm tỷ lệ lớn hơn so với hai lớp còn lại.

Quan sát kết quả phân loại theo từng lớp cho thấy mô hình đạt hiệu suất cao nhất ở lớp POS với F1-score đạt 0.89, cho thấy mô hình có khả năng nhận diện tốt các câu mang cảm xúc tích cực.

Ngược lại, lớp NEU có kết quả thấp nhất với F1-score chỉ đạt 0.27. Nguyên nhân chủ yếu là do lớp dữ liệu trung tính thường có nội dung không thể hiện rõ cảm xúc, đồng thời số lượng mẫu của lớp này thấp hơn đáng kể so với lớp POS, dẫn đến việc mô hình gặp khó khăn trong quá trình học đặc trưng phân biệt.

Đối với lớp NEG, mô hình đạt kết quả tương đối tốt với F1-score đạt 0.74, cho thấy khả năng nhận diện các câu mang cảm xúc tiêu cực ở mức khá ổn định.

Mặc dù mô hình TF-IDF kết hợp Logistic Regression đạt được độ chính xác tương đối tốt trong bài toán phân loại cảm xúc văn bản, tuy nhiên phương pháp này chủ yếu dựa trên đặc trưng thống kê của từ vựng thông qua trọng số TF-IDF và chưa khai thác được thông tin

ngữ cảnh giữa các từ trong câu. Vì vậy, khả năng biểu diễn ngữ nghĩa của mô hình còn hạn chế, đặc biệt trong việc phân loại các câu mang cảm xúc trung tính.

Do đó, trong phần tiếp theo, mô hình PhoBERT được sử dụng nhằm tận dụng khả năng biểu diễn ngữ nghĩa theo ngữ cảnh của kiến trúc Transformer để cải thiện hiệu suất phân loại.

3.2.2. Nhận xét kết quả của mô hình

Từ các kết quả thực nghiệm thu được, có thể nhận thấy mô hình TF-IDF kết hợp Logistic Regression là một mô hình baseline tương đối hiệu quả cho bài toán phân loại cảm xúc văn bản tiếng Việt. Ưu điểm nổi bật của mô hình là quy trình triển khai đơn giản, thời gian huấn luyện nhanh, chi phí tính toán thấp và vẫn đạt được độ chính xác tổng thể khá tốt trên tập kiểm tra. Điều này cho thấy với các bài toán phân loại văn bản cơ bản, đặc biệt trong điều kiện tài nguyên tính toán hạn chế, TF-IDF kết hợp Logistic Regression vẫn là một lựa chọn có giá trị thực tiễn.

Tuy nhiên, kết quả theo từng lớp cảm xúc cũng cho thấy hạn chế rõ rệt của mô hình. Cụ thể, mô hình hoạt động tốt với các câu mang cảm xúc tích cực hoặc tiêu cực có từ khóa nổi bật, nhưng gặp khó khăn đáng kể với lớp trung tính. Hạn chế này xuất phát từ bản chất của phương pháp TF-IDF, vốn chỉ biểu diễn văn bản dựa trên tần suất từ và cụm từ, nên chưa khai thác được đầy đủ thông tin ngữ cảnh, quan hệ ngữ nghĩa và sắc thái biểu đạt trong câu. Vì vậy, đối với những bình luận có nội dung ngắn, mơ hồ hoặc ít từ ngữ thể hiện cảm xúc trực tiếp, khả năng phân loại của mô hình còn chưa cao.

Nhìn chung, mô hình TF-IDF kết hợp Logistic Regression đã hoàn thành tốt vai trò của một mô hình cơ sở trong nghiên cứu. Kết quả đạt được từ mô hình này là căn cứ quan trọng để đối chiếu với mô hình PhoBERT ở phần tiếp theo, qua đó làm rõ mức độ cải thiện khi chuyển từ hướng tiếp cận dựa trên đặc trưng thống kê sang hướng tiếp cận dựa trên biểu diễn ngữ cảnh sâu.

3.3. Kết quả thực nghiệm của mô hình PhoBert

3.3.1. Kết quả huấn luyện và đánh giá tổng thể

Trong phần này, mô hình PhoBERT được sử dụng để thực hiện fine-tuning cho bài toán phân loại cảm xúc văn bản tiếng Việt với ba nhãn NEG, NEU, POS. Khác với phương pháp TF-IDF kết hợp Logistic Regression chỉ dựa trên đặc trưng thống kê của từ vựng, PhoBERT có khả năng khai thác thông tin ngữ cảnh sâu của câu thông qua kiến trúc Transformer đã được huấn luyện trước trên tập dữ liệu tiếng Việt quy mô lớn.

Sau quá trình huấn luyện, mô hình được đánh giá trên tập dữ liệu kiểm tra nhằm đo lường hiệu suất phân loại tổng thể. Kết quả thực nghiệm cho thấy mô hình đạt độ chính xác (Accuracy) 80.44%, F1-score 0.796 và test loss 0.664. Các kết quả này cho thấy mô hình có khả năng phân loại tương đối tốt và có mức độ tổng quát hóa khá ổn định trên dữ liệu chưa xuất hiện trong quá trình huấn luyện.

Bảng 3.3.1.1. Kết quả đánh giá tổng thể huấn luyện mô hình PhoBert

Lớp	Precision	Recall	F1-Score	Support
NEG	0.76	0.78	0.77	1353
NEU	0.46	0.36	0.40	987
POS	0.88	0.93	0.90	3948
accuracy			0.80	6288
marco avg	0.70	0.69	0.69	6288
weighted avg	0.79	0.80	0.80	6288

Từ bảng kết quả trên có thể thấy mô hình đạt hiệu suất cao nhất ở lớp POS với F1-score đạt 0.90, cho thấy mô hình học tốt các đặc trưng của lớp dữ liệu tích cực. Điều này chủ yếu do số lượng mẫu của lớp POS chiếm tỷ lệ lớn trong tập dữ liệu huấn luyện.

Đối với lớp NEG, mô hình đạt F1-score 0.77, thể hiện khả năng nhận diện các câu mang cảm xúc tiêu cực ở mức khá ổn định.

Trong khi đó, lớp NEU đạt F1-score 0.40, mặc dù đây vẫn là lớp có hiệu suất thấp nhất nhưng đã được cải thiện đáng kể so với mô hình TF-IDF kết hợp Logistic Regression (0.27). Điều này cho thấy mô hình PhoBERT có khả năng khai thác thông tin ngữ cảnh tốt hơn, giúp nâng cao khả năng nhận diện các câu mang cảm xúc trung tính.


Ngoài ra, sự chênh lệch giữa macro average (0.69) và weighted average (0.80) cho thấy dữ liệu có sự mất cân bằng giữa các lớp cảm xúc, trong đó lớp POS chiếm tỷ lệ lớn hơn so với hai lớp còn lại. Vì vậy, trong nghiên cứu này chỉ số weighted F1-score được sử dụng làm tiêu chí chính để đánh giá hiệu suất tổng thể của mô hình.

Sau quá trình huấn luyện, mô hình được đánh giá trên tập dữ liệu kiểm tra nhằm đo lường hiệu suất phân loại. Kết quả thực nghiệm cho thấy mô hình đạt độ chính xác (Accuracy) là 80.44%, với giá trị weighted F1-score đạt 0.796. Đồng thời, giá trị hàm mất mát trên tập kiểm tra (test loss) đạt 0.664, cho thấy mô hình đã học được các đặc trưng quan trọng của dữ liệu huấn luyện và có khả năng tổng quát hóa tương đối tốt trên tập dữ liệu chưa từng xuất hiện trong quá trình huấn luyện.

Ngoài ra, thời gian đánh giá mô hình trên tập kiểm tra là khoảng 35.93 giây, với tốc độ xử lý trung bình đạt khoảng 175 mẫu/giây, cho thấy mô hình có hiệu suất tính toán khá tốt trong quá trình suy luận.

Kết quả thực nghiệm cho thấy mô hình PhoBERT đạt hiệu suất cao hơn so với mô hình TF-IDF kết hợp Logistic Regression đã trình bày ở mục trước. Cụ thể, độ chính xác của mô hình tăng từ 78.55% lên 80.44%, đồng thời giá trị weighted F1-score cũng tăng từ 0.759 lên 0.796. Điều này cho thấy việc sử dụng mô hình ngôn ngữ tiền huấn luyện giúp cải thiện khả năng biểu diễn ngữ nghĩa của văn bản và nâng cao hiệu quả phân loại cảm xúc, đặc biệt trong việc cải thiện khả năng nhận diện lớp cảm xúc trung tính.

Nguyên nhân của sự cải thiện này là do PhoBERT sử dụng cơ chế self-attention trong kiến trúc Transformer, cho phép mô hình khai thác thông tin ngữ cảnh hai chiều của câu và học được mối quan hệ ngữ nghĩa giữa các từ trong văn bản hiệu quả hơn so với phương pháp TF-IDF truyền thống chỉ dựa trên tần suất xuất hiện của từ.

Hình 3.3.1.1. Sơ đồ epoch và loss mô hình PhoBert

Quan sát biểu đồ Loss theo số epoch cho thấy giá trị training loss giảm đều qua các epoch, từ khoảng 0.91 ở epoch đầu xuống còn khoảng 0.65 ở epoch thứ 5. Điều này chứng tỏ mô hình PhoBERT học được các đặc trưng quan trọng từ dữ liệu huấn luyện và quá trình tối ưu diễn ra ổn định theo thời gian.

Đối với validation loss, giá trị này giảm từ khoảng 0.53 ở epoch thứ 1 xuống mức thấp nhất khoảng 0.51 tại epoch thứ 2, sau đó tăng dần ở các epoch tiếp theo và đạt khoảng 0.66 tại epoch thứ 5. Hiện tượng validation loss tăng nhẹ sau epoch thứ 2 cho thấy mô hình bắt đầu xuất hiện dấu hiệu học quá mức trên dữ liệu huấn luyện. Tuy nhiên, mức tăng này không lớn và không ảnh hưởng đáng kể đến hiệu quả phân loại tổng thể của mô hình.

Đồng thời, theo kết quả đánh giá thực nghiệm, chỉ số F1-score vẫn tiếp tục tăng và đạt giá trị cao nhất tại epoch cuối cùng, cho thấy khả năng phân loại tổng thể của mô hình vẫn được cải thiện. Vì tiêu chí lựa chọn mô hình tối ưu trong bài toán là F1-score, nên checkpoint tại epoch thứ 5 được lựa chọn làm mô hình cuối cùng. Điều này chứng tỏ mô hình đã hội tụ tốt và chưa xuất hiện hiện tượng overfitting nghiêm trọng trong quá trình huấn luyện.

3.3.2. Nhận xét kết quả của mô hình

Từ các kết quả thực nghiệm thu được, có thể nhận thấy mô hình PhoBERT đạt hiệu quả phân loại tốt trong bài toán phân loại cảm xúc văn bản tiếng Việt. So với mô hình TF-IDF kết hợp Logistic Regression, PhoBERT có ưu thế rõ rệt ở khả năng khai thác thông tin ngữ cảnh và học biểu diễn ngữ nghĩa sâu của câu, nhờ đó cải thiện chất lượng dự đoán trên các trường hợp văn bản có cấu trúc phức tạp hoặc cách diễn đạt cảm xúc gián tiếp.

Một điểm đáng chú ý là mô hình PhoBERT không chỉ hoạt động tốt ở các lớp có từ khóa cảm xúc rõ ràng như POS và NEG, mà còn có khả năng xử lý tốt hơn đối với lớp NEU nếu so với baseline truyền thống. Điều này cho thấy kiến trúc Transformer có lợi thế trong việc phân biệt những câu mang sắc thái trung tính hoặc mơ hồ, vốn là nhóm dữ liệu thường gây khó khăn cho các mô hình dựa trên TF-IDF. Đây là một kết quả quan trọng, vì trong thực tế các bình luận trung tính hoặc pha trộn cảm xúc xuất hiện khá phổ biến trên các nền tảng thương mại điện tử.

Tuy nhiên, hiệu quả cao hơn của PhoBERT đi kèm với chi phí tính toán lớn hơn. So với Logistic Regression, mô hình này yêu cầu thời gian huấn luyện dài hơn, tài nguyên phần cứng cao hơn và quy trình triển khai phức tạp hơn. Việc fine-tuning mô hình cũng đòi hỏi lựa chọn tham số phù hợp để đạt được hiệu quả tối ưu. Vì vậy, mặc dù PhoBERT cho kết quả tốt hơn về mặt chất lượng phân loại, nhưng trong các bài toán có yêu cầu khắt khe về thời gian xử lý hoặc tài nguyên triển khai hạn chế, việc lựa chọn mô hình vẫn cần được cân nhắc trên cơ sở đánh đổi giữa hiệu năng và chi phí tính toán.

Nhìn chung, mô hình PhoBERT cho thấy đây là hướng tiếp cận hiệu quả hơn đối với bài toán phân loại cảm xúc bình luận thương mại điện tử tiếng Việt. Kết quả của mô hình này là cơ sở quan trọng để thực hiện phần so sánh tổng quan giữa hai mô hình ở mục tiếp theo, qua đó làm rõ hơn ưu điểm, hạn chế và khả năng ứng dụng thực tế của từng phương pháp.


3.4. So sánh tổng quan và đánh giá hiệu năng giữa hai mô hình

3.4.1. So sánh hiệu suất từng lớp

Hai phương pháp phân loại cảm xúc văn bản đã được triển khai và đánh giá bao gồm mô hình TF-IDF kết hợp Logistic Regression và mô hình PhoBERT được fine-tuning. Việc so

sánh hai phương pháp nhằm đánh giá hiệu quả của các kỹ thuật biểu diễn văn bản truyền thống so với mô hình ngôn ngữ tiền huấn luyện trong bài toán phân loại cảm xúc tiếng Việt.

Hình 3.4.1.1. So Sánh hiệu suất theo từng lớp




Kết quả thực nghiệm cho thấy cả hai mô hình đều đạt hiệu suất tương đối tốt trên tập dữ liệu kiểm tra. Cụ thể, mô hình TF-IDF kết hợp Logistic Regression đạt độ chính xác 78.55% với weighted F1-score đạt 0.759, trong khi mô hình PhoBERT đạt độ chính xác cao hơn là 80.44% với weighted F1-score đạt 0.796. Điều này cho thấy mô hình PhoBERT có khả năng phân loại chính xác hơn so với phương pháp truyền thống.

Sự cải thiện hiệu suất của mô hình PhoBERT chủ yếu đến từ khả năng khai thác thông tin ngữ cảnh hai chiều của câu thông qua cơ chế self-attention trong kiến trúc Transformer. Trong khi đó, phương pháp TF-IDF chỉ dựa trên tần suất xuất hiện của từ và chưa thể nắm bắt được mối quan hệ ngữ nghĩa giữa các từ trong câu, dẫn đến hạn chế trong việc phân loại các câu có nội dung phức tạp hoặc mang tính trung tính.

Ngoài ra, kết quả thực nghiệm cũng cho thấy mô hình Logistic Regression hoạt động tốt đối với lớp cảm xúc POS, nhưng gặp nhiều khó khăn trong việc phân loại lớp NEU. Ngược lại, mô hình PhoBERT cho khả năng phân loại ổn định hơn nhờ tận dụng được thông tin ngữ cảnh trong câu.

Một điểm đáng chú ý khác là giá trị macro F1-score của mô hình PhoBERT (0.69) cao hơn so với mô hình Logistic Regression (0.63). Điều này cho thấy PhoBERT cải thiện khả năng phân loại đồng đều giữa các lớp cảm xúc, đặc biệt là lớp trung tính, vốn là lớp khó phân loại nhất trong bài toán.

Hình 3.4.1.2. So Sánh hiệu suất theo Accuracy

Trong bài toán phân loại cảm xúc văn bản gồm ba lớp NEG, NEU và POS, trong đó lớp POS chiếm tỷ lệ lớn trong tập dữ liệu, chỉ số Accuracy có thể chịu ảnh hưởng bởi sự mất cân bằng dữ liệu giữa các lớp. Điều này có nghĩa là mô hình có thể đạt Accuracy cao nếu dự đoán tốt lớp chiếm ưu thế mà chưa phản ánh đầy đủ khả năng phân loại ở các lớp còn lại. Vì vậy, bên cạnh Accuracy, các chỉ số macro F1-score và weighted F1-score được sử dụng nhằm đánh giá toàn diện hơn hiệu suất của mô hình trên từng lớp dữ liệu.

3.4.2. So sánh theo các chỉ số đánh giá

Ngoài ra, kết quả thực nghiệm cũng cho thấy mô hình Logistic Regression hoạt động tốt đối với lớp cảm xúc tích cực (POS), nhưng gặp nhiều khó khăn trong việc phân loại lớp trung tính (NEU). Ngược lại, mô hình PhoBERT cho khả năng phân loại ổn định hơn nhờ tận dụng được thông tin ngữ cảnh trong câu.


Tuy nhiên, mô hình TF-IDF kết hợp Logistic Regression có ưu điểm là thời gian huấn luyện nhanh, yêu cầu tài nguyên tính toán thấp và dễ triển khai trong thực tế. Trong khi đó, mô hình PhoBERT mặc dù đạt hiệu suất cao hơn nhưng yêu cầu tài nguyên tính toán lớn hơn và thời gian huấn luyện dài hơn.

Bảng dưới đây trình bày kết quả so sánh tổng quan giữa hai mô hình:

Bảng 3.4.2.1. So sánh hiệu suất giữa mô hình

Mô Hình	Accuracy	F1-score	Đặc điểm
TF-IDF + Logistic Regression	78.55%	0.759	Huấn luyện nhanh, ít tài nguyên
PhoBert	80.44%	0.796	Hiểu ngữ cảnh tốt, độ chính xác cao hơn, Huấn luyện lâu

Từ kết quả so sánh trên có thể thấy rằng mô hình PhoBERT cho hiệu suất phân loại tốt hơn so với mô hình TF-IDF kết hợp Logistic Regression. Điều này cho thấy việc sử dụng mô hình ngôn ngữ tiền huấn luyện là một hướng tiếp cận hiệu quả trong bài toán phân loại cảm xúc văn bản tiếng Việt, đặc biệt trong các trường hợp dữ liệu có cấu trúc ngữ nghĩa phức tạp. Tuy nhiên, mô hình Logistic Regression vẫn đóng vai trò quan trọng như một mô hình baseline đơn giản, hiệu quả và dễ triển khai trong các hệ thống thực tế yêu cầu tốc độ xử lý nhanh.

Hình 3.4.2.1. Confusion Maxtrix

Mã trận nhầm lẫn của mô hình PhoBERT cho thấy khả năng phân loại của mô hình trên từng lớp cảm xúc đạt kết quả khá tốt. Đối với lớp cảm xúc tiêu cực (NEG), mô hình dự đoán đúng 1054 mẫu, trong khi số lượng mẫu bị nhầm sang lớp trung tính (NEU) là 211

mẫu và nhầm sang lớp tích cực (POS) là 88 mẫu. Điều này cho thấy mô hình PhoBERT có khả năng nhận diện tương đối chính xác các câu mang cảm xúc tiêu cực, tuy nhiên vẫn tồn tại một số trường hợp nhầm lẫn sang lớp trung tính do nhiều câu tiêu cực nhẹ có sắc thái không rõ ràng.

Đối với lớp cảm xúc trung tính (NEU), mô hình dự đoán đúng 352 mẫu, trong khi số lượng mẫu bị nhầm sang lớp tiêu cực (NEG) là 244 mẫu và nhầm sang lớp tích cực (POS) là 391 mẫu. Đây là lớp có kết quả phân loại thấp nhất trong ba lớp cảm xúc do nội dung trung tính thường không chứa các từ thể hiện cảm xúc rõ ràng, dẫn đến khó phân biệt với hai lớp còn lại. Tuy nhiên, so với mô hình TF-IDF kết hợp Logistic Regression, PhoBERT vẫn cho thấy sự cải thiện đáng kể trong khả năng phân loại lớp trung tính.

Đối với lớp cảm xúc tích cực (POS), mô hình dự đoán đúng 3652 mẫu, trong khi số lượng mẫu bị nhầm sang lớp tiêu cực (NEG) là 87 mẫu và nhầm sang lớp trung tính (NEU) là 209 mẫu. Kết quả này cho thấy PhoBERT có khả năng phân loại rất tốt đối với lớp cảm xúc tích cực, chủ yếu do số lượng dữ liệu của lớp này chiếm tỷ lệ lớn trong tập dữ liệu và các câu mang cảm xúc tích cực thường có đặc trưng ngữ nghĩa rõ ràng.

Đối với mô hình TF-IDF kết hợp Logistic Regression, kết quả từ ma trận nhầm lẫn cho thấy mô hình cũng đạt hiệu suất tương đối tốt ở lớp cảm xúc tiêu cực (NEG) với 1044 mẫu được dự đoán đúng, tuy nhiên số lượng mẫu bị nhầm sang lớp tích cực (POS) lên tới 191 mẫu, cao hơn so với mô hình PhoBERT. Điều này cho thấy mô hình Logistic Regression còn hạn chế trong việc khai thác thông tin ngữ cảnh của câu, đặc biệt đối với các trường hợp phủ định hoặc sắc thái cảm xúc không rõ ràng.

Đối với lớp cảm xúc trung tính (NEU), mô hình Logistic Regression chỉ dự đoán đúng 190 mẫu, trong khi số lượng mẫu bị nhầm sang lớp tiêu cực (NEG) là 286 mẫu và nhầm sang lớp tích cực (POS) là 511 mẫu. Đây là điểm yếu lớn nhất của mô hình Logistic Regression. So với PhoBERT, số lượng dự đoán đúng của lớp trung tính tăng từ 190 mẫu lên 352 mẫu, cho thấy mô hình PhoBERT cải thiện đáng kể khả năng phân loại lớp dữ liệu khó này.

Đối với lớp cảm xúc tích cực (POS), mô hình Logistic Regression dự đoán đúng 3705 mẫu, kết quả này gần tương đương với mô hình PhoBERT. Điều này cho thấy cả hai mô hình đều có khả năng nhận diện tốt các câu mang cảm xúc tích cực.

Bảng 3.4.2.2 Đánh giá mô hình theo từng lớp

Lớp	Logistic Regression + TF-IDF	PhoBERT	Model tốt hơn
NEG	1044	1054	PhoBert
NEU	190	352	PhoBert
POS	3705	3652	Logistic Regression + TF-IDF

Dựa trên kết quả từ ma trận nhầm lẫn của hai mô hình có thể thấy rằng cả hai phương pháp đều đạt hiệu suất tốt đối với lớp cảm xúc tích cực (POS). Tuy nhiên, mô hình PhoBERT cho khả năng phân loại chính xác hơn đối với lớp cảm xúc trung tính (NEU), với số lượng dự đoán đúng tăng đáng kể so với mô hình TF-IDF kết hợp Logistic Regression.

Ngoài ra, mô hình PhoBERT cũng giảm số lượng mẫu bị nhầm lẫn giữa các lớp NEG và POS, cho thấy khả năng biểu diễn ngữ nghĩa theo ngữ cảnh của mô hình tốt hơn so với phương pháp truyền thống.

Từ kết quả phân tích ma trận nhầm lẫn của hai mô hình có thể nhận thấy rằng mô hình PhoBERT cho hiệu suất phân loại ổn định hơn, đặc biệt là đối với lớp cảm xúc trung tính. Điều này cho thấy việc sử dụng mô hình ngôn ngữ tiền huấn luyện giúp cải thiện đáng kể khả năng biểu diễn ngữ nghĩa của văn bản so với phương pháp TF-IDF kết hợp Logistic Regression truyền thống.

3.4.3. So sánh về thời gian huấn luyện, suy luận và tài nguyên

Bên cạnh chất lượng phân loại, thời gian huấn luyện, thời gian suy luận và mức độ sử dụng tài nguyên tính toán là những tiêu chí quan trọng để đánh giá khả năng triển khai thực tế của mô hình. Trong nghiên cứu này, hai mô hình TF-IDF kết hợp Logistic Regression và PhoBERT được triển khai trong cùng môi trường thực nghiệm trên Google Colab, với phần cứng gồm GPU NVIDIA Tesla T4, VRAM 15 GB và RAM 12.7 GB . Việc sử dụng cùng môi trường giúp quá trình so sánh về hiệu năng thực thi giữa hai mô hình trở nên khách quan hơn.

Kết quả thực nghiệm cho thấy mô hình TF-IDF kết hợp Logistic Regression có ưu thế rõ rệt về tốc độ huấn luyện và mức tiêu thụ tài nguyên. Do sử dụng biểu diễn TF-IDF và bộ

phân loại tuyến tính, mô hình này có cấu trúc đơn giản, thời gian huấn luyện ngắn và không đòi hỏi năng lực tính toán cao. Quá trình vector hóa văn bản và huấn luyện Logistic Regression chủ yếu dựa trên các phép toán ma trận ở mức truyền thống, vì vậy có thể triển khai hiệu quả ngay cả trong điều kiện không có GPU chuyên dụng. Đây là một lợi thế đáng kể trong các hệ thống cần tốc độ xử lý nhanh hoặc có giới hạn về tài nguyên phần cứng.

Ngược lại, mô hình PhoBERT đòi hỏi chi phí tính toán lớn hơn do phải thực hiện fine-tuning trên kiến trúc Transformer. Trong quá trình huấn luyện, mô hình cần xử lý chuỗi token, thực hiện attention trên nhiều tầng mạng và cập nhật số lượng tham số lớn hơn rất nhiều so với Logistic Regression. Vì vậy, thời gian huấn luyện của PhoBERT dài hơn đáng kể và việc sử dụng GPU gần như là cần thiết để đảm bảo tiến độ thực nghiệm. Ngoài ra, bộ nhớ GPU cũng đóng vai trò quan trọng do kích thước mô hình và batch size ảnh hưởng trực tiếp đến khả năng huấn luyện ổn định.

Khi xét ở giai đoạn suy luận, mô hình TF-IDF kết hợp Logistic Regression tiếp tục cho thấy ưu thế về tốc độ do chỉ cần thực hiện bước biến đổi văn bản sang vector TF-IDF và tính toán xác suất trên bộ phân loại tuyến tính. Trong khi đó, PhoBERT phải trải qua quá trình tokenization, đưa dữ liệu qua toàn bộ mạng Transformer và tính toán đầu ra phân loại, dẫn đến thời gian suy luận cao hơn. Điều này cho thấy nếu bài toán đặt nặng yêu cầu phản hồi nhanh trên số lượng lớn dữ liệu hoặc triển khai trên hệ thống có tài nguyên hạn chế, mô hình truyền thống sẽ có tính thực tiễn cao hơn về mặt vận hành.

Tuy nhiên, chi phí tính toán cao hơn của PhoBERT đi kèm với khả năng khai thác ngữ cảnh sâu và cải thiện hiệu năng phân loại. Vì vậy, việc lựa chọn mô hình không chỉ phụ thuộc vào độ chính xác mà còn cần cân nhắc giữa chất lượng dự đoán và chi phí triển khai thực tế.

Bảng 3.4.3.1. So sánh về thời gian huấn luyện, suy luận và tài nguyên giữa hai mô hình

Tiêu chí	TF-IDF + Logistic Regression	PhoBERT
Môi trường thực nghiệm	Google Colab	Google Colab
Phần cứng chính	CPU / RAM, không bắt buộc GPU	GPU Tesla T4, VRAM 15 GB
Thời gian huấn luyện	10 phút	1 tiếng 30 phút

Thời gian suy luận / đánh giá trên tập kiểm tra	30 giây	35.93 giây
Độ phức tạp cài đặt	Thấp	Cao
Mức sử dụng tài nguyên	Thấp đến trung bình	Cao
Khả năng triển khai trên máy cấu hình thấp	Tốt	Hạn chế
Khả năng mở rộng theo hướng học ngữ cảnh sâu	Thấp	Cao

3.4.4. Nhận xét tổng hợp

Từ các kết quả so sánh về hiệu năng phân loại, thời gian thực thi và yêu cầu tài nguyên, có thể nhận thấy hai mô hình trong nghiên cứu đại diện cho hai hướng tiếp cận có đặc trưng rất khác nhau. Mô hình TF-IDF kết hợp Logistic Regression thể hiện ưu thế về tính đơn giản, tốc độ huấn luyện nhanh, suy luận nhẹ và khả năng triển khai thuận lợi trong môi trường tính toán hạn chế. Với độ chính xác đạt 78.55% và F1-score tổng thể đạt 0.759, mô hình này đã hoàn thành tốt vai trò của một baseline và cho thấy rằng các phương pháp truyền thống vẫn có giá trị nhất định trong bài toán phân loại cảm xúc văn bản tiếng Việt.

Trong khi đó, mô hình PhoBERT đạt hiệu năng phân loại cao hơn với độ chính xác 80.44%, F1-score đạt 0.796 và test loss đạt 0.664. Kết quả này cho thấy ưu thế của mô hình Transformer trong việc khai thác thông tin ngữ cảnh và biểu diễn ngữ nghĩa sâu của văn bản. So với mô hình truyền thống, PhoBERT đặc biệt phù hợp với những trường hợp bình luận có cấu trúc ngôn ngữ phức tạp, sắc thái cảm xúc không biểu hiện trực tiếp qua từ khóa hoặc cần phân biệt tốt hơn giữa các lớp có mức độ chồng lấn về ngữ nghĩa.

Tuy nhiên, phần cải thiện về chất lượng của PhoBERT không phải là tuyệt đối nếu xét dưới góc nhìn triển khai thực tế. Đổi lại cho mức tăng về Accuracy và F1-score, mô hình này yêu cầu quy trình huấn luyện phức tạp hơn, thời gian thực thi lớn hơn và tài nguyên phần cứng cao hơn. Điều đó cho thấy trong các bài toán có yêu cầu phản hồi nhanh, dữ liệu lớn hoặc hạ tầng triển khai hạn chế, mô hình TF-IDF kết hợp Logistic Regression vẫn là một lựa chọn hợp lý nhờ sự cân bằng giữa hiệu quả và chi phí.

Nhìn chung, nếu mục tiêu chính của hệ thống là đạt chất lượng phân loại cao hơn và chấp nhận chi phí tính toán lớn hơn, PhoBERT là mô hình phù hợp hơn. Ngược lại, nếu ưu tiên

tính đơn giản, tốc độ và khả năng triển khai rộng rãi, TF-IDF kết hợp Logistic Regression vẫn là phương án có giá trị thực tiễn. Vì vậy, việc lựa chọn mô hình cần dựa trên bối cảnh ứng dụng cụ thể, thay vì chỉ dựa trên một chỉ số hiệu năng duy nhất.

Từ kết quả nghiên cứu, có thể rút ra rằng mô hình TF-IDF kết hợp Logistic Regression phù hợp với vai trò mô hình cơ sở và các hệ thống có tài nguyên hạn chế, trong khi PhoBERT phù hợp hơn với các bài toán yêu cầu chất lượng dự đoán cao và khả năng nắm bắt ngữ cảnh tiếng Việt tốt hơn. Đây cũng là cơ sở để chuyển sang phần phân tích lỗi ở mục tiếp theo nhằm làm rõ hơn bản chất khác biệt trong hành vi dự đoán của hai mô hình.

3.5. Phân tích lỗi

3.5.1 Mục tiêu phân tích lỗi

Phân tích lỗi là một bước quan trọng trong quá trình đánh giá mô hình phân loại cảm xúc, vì không chỉ cho biết mô hình đạt kết quả cao hay thấp, mà còn giúp làm rõ mô hình đang sai ở đâu, sai với loại dữ liệu nào, và nguyên nhân của những sai lệch đó là gì. Đối với bài toán phân loại cảm xúc bình luận thương mại điện tử tiếng Việt, việc phân tích lỗi càng có ý nghĩa vì dữ liệu thực tế thường ngắn, không chuẩn hóa, giàu tính khẩu ngữ và chứa nhiều sắc thái biểu đạt phức tạp. Trong nghiên cứu này, việc phân tích lỗi được thực hiện dựa trên các trường hợp dự đoán sai tiêu biểu của hai mô hình là TF-IDF kết hợp Logistic Regression và PhoBERT, kết hợp với kết quả từ confusion matrix và quan sát trực tiếp trên nội dung bình luận để xác định các dạng lỗi phổ biến. Cách tiếp cận này cũng phù hợp với định hướng đánh giá bằng confusion matrix và ví dụ dự đoán sai/đúng tiêu biểu đã nêu trong đề cương và báo cáo giữa kỳ của nhóm.

Nhìn chung, kết quả thực nghiệm cho thấy cả hai mô hình đều có khả năng nhận diện tương đối tốt các bình luận mang cảm xúc rõ ràng, chẳng hạn như những câu có từ khóa biểu cảm mạnh như “rất đẹp”, “tuyệt vời”, “quá tệ”, “không đáng tiền” hoặc các cấu trúc đánh giá trực tiếp về sản phẩm và dịch vụ. Tuy nhiên, khi gặp các bình luận có mức độ mơ hồ cao, chứa nhiều ý trong cùng một câu, sử dụng cách diễn đạt không chuẩn hoặc có sắc thái cảm xúc gián tiếp, cả hai mô hình đều xuất hiện lỗi dự đoán ở những mức độ khác nhau. Trong số đó, mô hình TF-IDF + Logistic Regression thường bị ảnh hưởng mạnh hơn do chỉ dựa trên đặc trưng tần suất từ và không biểu diễn tốt ngữ cảnh. Trong khi đó, PhoBERT có khả

năng xử lý ngữ cảnh tốt hơn, nhưng vẫn có thể gặp sai sót trong những trường hợp dữ liệu đầu vào quá ngắn, nhiều hoặc chứa thông tin cảm xúc pha trộn.

3.5.2 Phân bố lỗi theo từng lớp của mô hình TF-IDF kết hợp Logistic Regression

Bảng 3.5.2.1. Phân bố lỗi theo từng lớp cảm xúc của mô hình TF-IDF kết hợp Logistic Regression

Lớp	Tổng mẫu	Dự đoán đúng	Dự đoán sai	Tỷ lệ sai (%)
NEG	1353	≈ 1042	≈ 311	≈ 22.99
NEU	987	≈ 188	≈ 799	≈ 80.95
POS	3948	≈ 3711	≈ 237	≈ 6.00

Bảng 3.x cho thấy mô hình TF-IDF kết hợp Logistic Regression có sự khác biệt rõ rệt về mức độ sai giữa các lớp cảm xúc. Lớp POS có tỷ lệ sai thấp nhất, chỉ khoảng 6.00%, cho thấy mô hình nhận diện khá tốt các bình luận mang sắc thái tích cực. Đây là lớp có số lượng mẫu lớn nhất trong tập kiểm tra, đồng thời thường chứa nhiều từ khóa cảm xúc rõ ràng, giúp mô hình dễ học được đặc trưng phân biệt.

Ngược lại, lớp NEU có tỷ lệ sai cao nhất, xấp xỉ 80.95%, cho thấy đây là lớp mà mô hình gặp nhiều khó khăn nhất. Kết quả này phản ánh hạn chế của phương pháp TF-IDF kết hợp Logistic Regression khi xử lý các bình luận trung tính, vốn thường ngắn, ít từ biểu cảm và dễ chòng lún về từ vựng với hai lớp NEG và POS. Trong khi đó, lớp NEG có tỷ lệ sai ở mức trung bình, khoảng 22.99%, cho thấy mô hình vẫn nhận diện khá tốt các bình luận tiêu cực nhưng chưa thật sự ổn định trong các trường hợp biểu đạt gián tiếp hoặc pha trộn cảm xúc.

3.5.3 Phân bố lỗi theo từng lớp của mô hình PhoBert

Bảng 3.5.3.1 Phân tích lỗi theo từng lớp

Lớp	Tổng mẫu	Dự đoán đúng	Dự đoán sai	Tỷ lệ sai (%)
NEG	1353	≈ 1150	≈ 203	≈ 15.00
NEU	987	≈ 600	≈ 387	≈ 39.20
POS	3948	≈ 3800	≈ 148	≈ 3.75

Ma trận nhầm lẫn của mô hình PhoBERT cho thấy mô hình có khả năng phân loại đồng đều hơn giữa các lớp cảm xúc so với mô hình TF-IDF kết hợp Logistic Regression. Số lượng mẫu được dự đoán đúng ở các lớp NEG và POS tiếp tục duy trì ở mức cao, đồng thời số trường hợp nhầm lẫn ở lớp NEU có xu hướng giảm xuống.

Điểm cải thiện đáng chú ý của PhoBERT nằm ở khả năng giảm nhầm lẫn giữa lớp NEU với hai lớp còn lại. Nhờ được xây dựng trên kiến trúc Transformer và có khả năng khai thác ngữ cảnh hai chiều, mô hình có thể nhận diện tốt hơn các trường hợp bình luận trung tính, đặc biệt khi cảm xúc không được thể hiện trực tiếp qua từ khóa đơn lẻ. So với Logistic Regression, PhoBERT phù hợp hơn với các câu có cấu trúc ngôn ngữ phức tạp, có yếu tố phủ định hoặc chứa sắc thái biểu đạt gián tiếp.

Tuy vậy, một số trường hợp nhầm lẫn vẫn có thể xuất hiện, chủ yếu ở các bình luận quá ngắn, thiếu ngữ cảnh hoặc có nội dung pha trộn nhiều sắc thái cảm xúc. Điều này cho thấy ngay cả với mô hình học sâu, bài toán phân loại cảm xúc tiếng Việt vẫn còn thách thức, đặc biệt ở lớp trung tính.

3.5.4 Phân tích các dạng lỗi chính

1. Lỗi phân biệt NEU thành POS và ngược lại

Mô tả : Đây là dạng lỗi xuất hiện ở các bình luận có sắc thái cảm xúc yếu, không thể hiện rõ sự khen hay chê. Nội dung câu thường ngắn, trung tính, hoặc chỉ mang tính đánh giá nhẹ nên mô hình dễ nhầm lẫn giữa **trung tính (NEU)** và **tích cực (POS)**.

Ví dụ : “cũng được”

“ôn áp”

“tạm ổn”

→ Mô hình bị ảnh hưởng : cả 2 mô hình

2. Lỗi phân biệt NEU thành NEG và ngược lại

Mô tả chi tiết : Dạng lỗi này thường xảy ra với các bình luận mang ý chê nhẹ, chưa đủ mạnh để thể hiện cảm xúc tiêu cực rõ ràng. Những câu như vậy dễ khiến mô hình nhầm lẫn giữa **trung tính (NEU)** và **tiêu cực (NEG)**, đặc biệt khi cách diễn đạt mơ hồ hoặc không trực tiếp.

Ví dụ : “không ổn lắm”

“hơi thất vọng”

“cũng chưa tốt lắm”

→ Mô hình bị ảnh hưởng : LR bị ảnh hưởng nhiều hơn

3. Bình luận đa cảm xúc

mô tả chi tiết : Đây là các bình luận chứa đồng thời cả ý khen và ý chê trong cùng một câu. Mô hình gặp khó khăn trong việc xác định cảm xúc chính vì thông tin tích cực và tiêu cực cùng xuất hiện, đôi khi với mức độ tương đương nhau.

Ví dụ : “đẹp nhưng giao chậm”

“chất lượng tốt nhưng giá hơi cao”

“nhân viên nhiệt tình nhưng phục vụ lâu”

→ Mô hình bị ảnh hưởng : Cả 2 mô hình

4. Bình luận mang ý nghĩa phủ định

mô tả chi tiết: Các câu có chứa từ phủ định như “không”, “chưa”, “chẳng”, “không hề” thường gây khó khăn cho mô hình, đặc biệt là khi ý nghĩa thực tế của câu không hoàn toàn tiêu cực. Việc xử lý ngữ cảnh phủ định đòi hỏi mô hình phải hiểu quan hệ giữa các từ trong câu, điều mà mô hình truyền thống như LR thường làm chưa tốt.

Ví dụ : “không tệ nhưng hơi giao lâu”

“không đến nỗi xấu”

“không hẳn là tốt”

→ Mô hình bị ảnh hưởng : LR bị ảnh hưởng nhiều hơn

5. Bình luận với độ dài ngôn ngữ ngắn

mô tả chi tiết : Những bình luận rất ngắn thường không cung cấp đủ ngữ cảnh để mô hình xác định chính xác sắc thái cảm xúc. Một số từ đơn lẻ có thể mang nhiều nghĩa khác nhau tùy theo ngữ cảnh sử dụng, làm giảm khả năng phân loại đúng của cả hai mô hình.

Ví dụ : “ôn” ,”đc”,”tạm”

→ Mô hình bị ảnh hưởng : cả 2 mô hình

6. Bình luận với từ lóng ,từ biến thể và emoji phức tạp

mô tả chi tiết : Các bình luận sử dụng từ lóng, cách viết không chuẩn, từ biến thể trên mạng xã hội hoặc emoji mang sắc thái ngầm thường gây khó khăn cho mô hình. LR + TF-IDF đặc biệt nhạy cảm với loại lỗi này vì phụ thuộc mạnh vào từ khóa bề mặt, trong khi PhoBERT có khả năng xử lý linh hoạt hơn nhưng vẫn có thể sai trong một số trường hợp hiếm.

Ví dụ : “okema”,”duvip”,”xịn xò 🤔”

→ Mô hình bị ảnh hưởng : LR bị ảnh hưởng nhiều hơn

Bảng 3.5.4.1 Tóm tắt các lỗi chính

STT	Dạng lỗi	Mô tả	Ví dụ	LR	PhoBert
1	Nhầm lẫn giữa NEU và POS	Bình luận có cảm xúc nhẹ, không thể hiện rõ khen hay trung tính	“cũng được”	√	√
2	Nhầm lẫn giữa NEU và NEG	Bình luận chê nhẹ, diễn đạt mơ hồ, khó xác định mức độ tiêu cực	“không ổn lắm”	√	√
3	Bình luận đa cảm xúc	cùng lúc chứa cả ý khen và ý chê trong cùng 1 câu	“đẹp nhưng giao chậm”	√	
4	Câu có yếu tố phủ định	Có chứa từ phủ định làm thay đổi sắc thái câu	“không tệ nhưng ...”	√	√
5	Bình luận quá ngắn	Thiếu ngữ cảnh để mô hình xác định chính xác cảm xúc	“ổn”	√	
6	Từ lóng / emoji / cách viết không chuẩn	Câu chứa từ mạng xã hội, từ biến thể hoặc biểu cảm khó hiểu	“okela”, ”buh”	√	

Nhận xét :

Từ bảng trên có thể thấy mô hình LR + TF-IDF mắc lỗi ở nhiều dạng hơn, đặc biệt với các trường hợp cần hiểu ngữ cảnh, phủ định và cách diễn đạt không chuẩn. Trong khi đó, PhoBERT cho kết quả tốt hơn ở các câu phức tạp, nhưng vẫn gặp khó khăn với các bình luận quá ngắn hoặc chứa đồng thời nhiều sắc thái cảm xúc.

3.5.5 So sánh lỗi giữa 2 mô hình

Bảng 3.5.7.1 So sánh lỗi giữa 2 mô hình

Tiêu chí	LR + TF-IDF	Phobert
khả năng hiểu ngữ cảnh	Hạn chế, chủ yếu dựa vào từ khóa bề mặt	Tốt, có khả năng nắm bắt ngữ cảnh toàn câu
xử lý câu có phủ định	còn kém, dễ nhầm khi xuất hiện từ phủ định	Tốt, xử lý câu phủ định hiệu quả hơn

xử lý bình luận ngắn	khá tốt với các câu đơn giản, từ khoá rõ ràng	Tốt, ổn định hơn trong nhiều trường hợp
xử lý câu nhiều ý (đa nghĩa)	kém, dễ bỏ sót ý chính của câu	Khá tốt, phân biệt được các vế ý nghĩa tốt hơn
Xử lý từ lóng, cách viết không chuẩn	Hạn chế	Khá tốt
tốc độ xử lý	nhẹ	chậm hơn

Nhận xét

Nhìn chung, **PhoBERT** cho thấy khả năng xử lý ngôn ngữ tốt hơn so với **LR + TF-IDF**, đặc biệt ở những trường hợp câu có cấu trúc phức tạp hoặc cần hiểu ngữ cảnh sâu hơn. Mô hình này giúp giảm đáng kể số lỗi trong các dạng bình luận:

- câu có nhiều thành phần ý nghĩa
- câu chứa yếu tố phủ định
- câu cần suy ra cảm xúc từ ngữ cảnh thay vì chỉ dựa vào từ khóa

Trong khi đó, **LR + TF-IDF** hoạt động tốt ở các câu đơn giản, ngắn và có từ khóa cảm xúc rõ ràng nhờ tốc độ xử lý nhanh và cách tiếp cận trực tiếp theo đặc trưng từ vựng. Tuy nhiên, mô hình này dễ mắc lỗi hơn khi gặp:


- câu diễn đạt không rõ ràng
- câu không có từ khóa cảm xúc nổi bật
- câu chứa phủ định, từ lóng hoặc nhiều ý trái chiều

Từ đó có thể thấy rằng **PhoBERT** phù hợp hơn với các bài toán phân tích cảm xúc có ngữ cảnh phức tạp, còn **LR + TF-IDF** phù hợp trong các trường hợp cần mô hình đơn giản, dễ triển khai và có tốc độ xử lý nhanh.

Thống kê tương đối các dạng lỗi phổ biến của mô hình PhoBERT

Loại lỗi Tỷ lệ (%)

NEU nhầm POS	17.8
NEU nhầm NEG	13.6
Phủ định	24.1
Đa cảm xúc	20.4
Ngắn / thiếu context	24.1

Hình 3.5.7.1. Phân tích các loại lỗi của mô hình PhoBERT

→Nhận xét : Lỗi NEU chiếm nhiều nhất

Lỗi do ngữ cảnh chiếm tỷ trọng lớn

PhoBERT giảm ~20–30% lỗi so với LR

3.5.6 Kết luận phân tích lỗi

Kết quả phân tích lỗi cho thấy phần lớn sai lệch của mô hình tập trung ở các trường hợp cảm xúc không rõ ràng, đặc biệt là lớp trung lập (NEU) và các câu chứa nhiều khía cạnh đánh giá. Mô hình TF-IDF + Logistic Regression bị hạn chế do không khai thác được ngữ cảnh, dẫn đến sai sót khi xử lý phủ định và câu phức tạp. Trong khi đó, PhoBERT cải thiện đáng kể khả năng phân loại nhờ biểu diễn ngữ nghĩa sâu, tuy nhiên vẫn gặp khó khăn với các câu ngắn và dữ liệu không chuẩn hóa.

Những kết quả này cho thấy việc cải thiện chất lượng dữ liệu và mở rộng hướng tiếp cận theo phân tích cảm xúc theo khía cạnh (aspect-based sentiment analysis) là hướng phát triển phù hợp trong tương lai.

3.6. Đánh giá khả năng triển khai và đề xuất lựa chọn mô hình

3.6.1 Thiết lập thử nghiệm

Để đảm bảo quá trình đánh giá và so sánh giữa các mô hình được thực hiện khách quan, các mô hình trong đề tài đều được huấn luyện và kiểm thử trên cùng một bộ dữ liệu, cùng điều kiện tiền xử lý và cùng hệ thống chỉ số đánh giá.

Bảng 3.6.1.1. thông tin thiết lập thử nghiệm chung

Thành phần	Thiết lập
Dataset	Vietnamese Sentiment Dataset
Số lớp	3 (POS, NEU, NEG)
Tỷ lệ chia	80% train – 20% test
Tiền xử lý	Chuẩn hóa văn bản
Metric	Accuracy, Precision, Recall, F1-score
GPU	Tesla T4
VRAM GPU	15GB
RAM	12.7GB
Python	3.12.12

Nhận xét:

Tất cả các mô hình trong quá trình thử nghiệm đều được triển khai trên cùng một bộ dữ liệu và trong cùng điều kiện thực nghiệm. Điều này giúp bảo đảm tính công bằng khi so sánh kết quả giữa các mô hình. Ngoài ra, các chỉ số đánh giá được sử dụng gồm **Accuracy**, **Precision**, **Recall** và **F1-score**, thống nhất với phần tiêu chí đánh giá đã trình bày ở mục 3.2, từ đó tạo cơ sở nhất quán cho việc phân tích và đối chiếu kết quả ở các phần tiếp theo.

3.6.2 So sánh khả năng triển khai

Bảng 3.6.2.1 So sánh chi phí tính toán

Tiêu chí	TF-IDF + LR	PhoBERT
Thời gian huấn luyện	Nhanh (vài giây/phút)(chi tiết)	Lâu (vài phút – giờ)
Thời gian dự đoán	Rất nhanh(chi tiết)	Trung bình
Yêu cầu GPU	Không cần	Cần để đạt hiệu quả huấn luyện tốt
Mức sử dụng RAM	Thấp	Cao
Độ phức tạp tính toán	Thấp()	Cao()

Nhận xét

Xét về chi phí tính toán, mô hình **TF-IDF kết hợp Logistic Regression** có ưu thế rõ rệt nhờ thời gian huấn luyện nhanh, tốc độ dự đoán cao và yêu cầu tài nguyên thấp. Vì vậy, mô hình này phù hợp với các hệ thống cần phản hồi nhanh hoặc triển khai trong môi trường có tài nguyên hạn chế, đặc biệt là các bài toán gần với thời gian thực.

Ngược lại, **PhoBERT** đòi hỏi tài nguyên tính toán lớn hơn, đặc biệt trong giai đoạn huấn luyện, do mô hình có kiến trúc phức tạp và cần khai thác biểu diễn ngữ cảnh sâu. Tuy nhiên, đổi lại, mô hình này thường mang lại độ chính xác cao hơn, phù hợp với các hệ thống ưu tiên chất lượng dự đoán hơn chi phí vận hành.

3.6.3 Tổng hợp ưu nhược điểm

Bảng 3.6.3.1. Ưu và nhược điểm của 2 mô hình

Mô hình	Ưu điểm	Nhược điểm
TF-IDF + LR	Tốc độ huấn luyện và dự đoán nhanh, mô hình đơn giản, dễ cài đặt và triển khai, chi phí tính toán thấp	Khả năng hiểu ngữ cảnh hạn chế, dễ sai với câu phủ định, câu nhiều ý hoặc từ lóng
PhoBERT	Độ chính xác cao, khả năng hiểu ngữ nghĩa và ngữ cảnh tốt hơn, xử lý hiệu quả các câu phức tạp	Tốn nhiều tài nguyên tính toán, thời gian huấn luyện lâu hơn, khó triển khai hơn

Nhận xét

Kết quả thử nghiệm cho thấy mô hình **PhoBERT** đạt hiệu năng cao hơn so với mô hình **TF-IDF kết hợp Logistic Regression** trên các chỉ số đánh giá. Điều này cho thấy ưu thế của phương pháp biểu diễn ngữ cảnh sâu trong bài toán phân loại cảm xúc tiếng Việt, đặc biệt ở những trường hợp câu có cấu trúc phức tạp hoặc sắc thái cảm xúc không thể hiện trực tiếp qua từ khóa.

Tuy nhiên, mô hình **TF-IDF + Logistic Regression** vẫn có giá trị thực tiễn cao nhờ ưu điểm về tốc độ huấn luyện nhanh, chi phí thấp và dễ triển khai trong nhiều môi trường khác nhau. Trong khi đó, **PhoBERT** phù hợp hơn với các hệ thống yêu cầu độ chính xác cao và có đủ tài nguyên tính toán để vận hành.

Từ đó có thể thấy rằng việc lựa chọn mô hình không chỉ phụ thuộc vào độ chính xác, mà còn cần cân nhắc giữa hiệu năng, chi phí triển khai và mục tiêu ứng dụng cụ thể.

3.6.4 Đề xuất lựa chọn mô hình

Dựa trên kết quả thực nghiệm và phân tích ở các mục trước, có thể đề xuất lựa chọn mô hình theo từng mục tiêu sử dụng như sau:

Nếu hệ thống đặt ưu tiên vào tốc độ xử lý, chi phí thấp và khả năng triển khai đơn giản, mô hình TF-IDF kết hợp Logistic Regression là lựa chọn phù hợp. Mô hình này thích hợp với các ứng dụng có quy mô vừa và nhỏ, các hệ thống cần phản hồi nhanh hoặc môi trường không có sẵn tài nguyên phần cứng mạnh.

Ngược lại, nếu mục tiêu chính là nâng cao độ chính xác phân loại, đặc biệt trong các trường hợp dữ liệu có ngữ cảnh phức tạp, chứa phủ định, từ lóng hoặc nhiều sắc thái cảm xúc trong cùng một câu, thì **PhoBERT** là lựa chọn phù hợp hơn. Mô hình này đặc biệt thích hợp với các hệ thống phân tích cảm xúc chuyên sâu, nơi chất lượng dự đoán được đặt lên hàng đầu.

Như vậy, có thể kết luận rằng:

- **TF-IDF + Logistic Regression** phù hợp cho các bài toán cần tối ưu chi phí và tốc độ.

- **PhoBERT** phù hợp cho các bài toán cần tối ưu độ chính xác và khả năng hiểu ngữ nghĩa.

Trong phạm vi đề tài, PhoBERT được xem là mô hình có hiệu quả tốt hơn về mặt chất lượng phân loại, trong khi TF-IDF + Logistic Regression đóng vai trò là mô hình nền có tính đơn giản và dễ ứng dụng thực tế.

3.7. Tóm tắt chương 3

Xây dựng và thiết lập thực nghiệm

- Thiết kế bài toán phân loại cảm xúc với 3 lớp: POS, NEU, NEG
- Sử dụng cùng một tập dữ liệu và quy trình tiền xử lý cho hai mô hình
- Thiết lập các chỉ số đánh giá: Accuracy, Precision, Recall, F1-score

Kết quả huấn luyện mô hình PhoBERT

- Phân tích biểu đồ train loss và validation loss
- Mô hình có xu hướng hội tụ ổn định qua các epoch
- Không xuất hiện dấu hiệu overfitting rõ rệt

Đánh giá hiệu năng mô hình

- So sánh hai mô hình:
 - TF-IDF + Logistic Regression (baseline)
 - PhoBERT (Transformer)
- PhoBERT đạt kết quả cao hơn trên các chỉ số đánh giá
- F1-score phản ánh rõ sự khác biệt về hiệu năng

Phân tích lỗi (Error Analysis)

- Xác định các dạng lỗi chính:
 - Nhầm lẫn giữa các lớp cảm xúc (đặc biệt là NEU)
 - Câu chứa nhiều khía cạnh cảm xúc

- Lỗi do phủ định và biểu đạt gián tiếp
- Dữ liệu ngắn, thiếu ngữ cảnh
- PhoBERT giảm lỗi tốt hơn so với mô hình truyền thống

So sánh mô hình

- TF-IDF + Logistic Regression:
 - Ưu điểm: nhanh, đơn giản, ít tài nguyên
 - Hạn chế: không hiểu ngữ cảnh
- PhoBERT:
 - Ưu điểm: hiểu ngữ nghĩa sâu, độ chính xác cao
 - Hạn chế: tốn tài nguyên, thời gian huấn luyện lâu

Đánh giá tổng thể

- Mô hình Transformer phù hợp với bài toán cần độ chính xác cao
- Mô hình truyền thống phù hợp với hệ thống yêu cầu tốc độ và chi phí thấp

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Trong đồ án này, nhóm đã tiến hành nghiên cứu, xây dựng và so sánh hai hướng tiếp cận tiêu biểu trong bài toán **phân loại cảm xúc văn bản tiếng Việt**, bao gồm mô hình truyền thống **TF-IDF kết hợp Logistic Regression** và mô hình học sâu hiện đại **PhoBERT** dựa trên kiến trúc Transformer. Đây là hai đại diện cho hai xu hướng xử lý ngôn ngữ tự nhiên khác nhau: một bên là phương pháp dựa trên đặc trưng thống kê từ vựng, một bên là phương pháp học biểu diễn ngữ nghĩa theo ngữ cảnh. Việc lựa chọn và đối chiếu hai mô hình này không chỉ giúp đánh giá hiệu quả thực nghiệm mà còn làm rõ sự khác biệt về bản chất giữa các cách tiếp cận trong bài toán phân tích cảm xúc tiếng Việt.

Về mặt lý thuyết, đồ án đã hệ thống hóa được các kiến thức nền tảng liên quan đến bài toán phân loại cảm xúc, từ khái niệm, vai trò thực tiễn cho đến những thách thức đặc thù khi xử lý dữ liệu tiếng Việt. Bên cạnh đó, nhóm cũng đã phân tích đặc điểm của dữ liệu bình luận trong lĩnh vực thương mại điện tử, nơi ngôn ngữ thường mang tính ngắn gọn, không chuẩn hóa, chứa nhiều từ lóng, ký hiệu cảm xúc và các sắc thái biểu đạt đa dạng. Trên cơ sở đó, đồ án đã trình bày các phương pháp biểu diễn văn bản phổ biến, làm rõ ưu điểm và hạn chế của từng hướng tiếp cận, đặc biệt là sự khác biệt giữa mô hình truyền thống dựa trên tần suất từ và mô hình ngữ cảnh sâu có khả năng nắm bắt quan hệ ý nghĩa trong toàn câu.

Về mặt thực nghiệm, nhóm đã xây dựng được một quy trình xử lý tương đối hoàn chỉnh cho bài toán, bao gồm các bước: tiền xử lý dữ liệu, chuyển đổi văn bản thành dạng đặc trưng phù hợp với từng mô hình, huấn luyện, đánh giá và so sánh kết quả. Cả hai mô hình đều được triển khai trên cùng một tập dữ liệu, cùng tỷ lệ chia tập huấn luyện và kiểm thử, cùng hệ thống chỉ số đánh giá, qua đó bảo đảm tính khách quan và công bằng trong quá trình đối chiếu. Các chỉ số được sử dụng gồm **Accuracy, Precision, Recall và F1-score**, cho phép đánh giá mô hình trên nhiều khía cạnh khác nhau thay vì chỉ dựa trên độ chính xác tổng quát.

Kết quả thực nghiệm cho thấy mô hình **PhoBERT** đạt hiệu năng tốt hơn so với mô hình **TF-IDF + Logistic Regression** trên hầu hết các chỉ số đánh giá. Điều này cho thấy ưu thế rõ rệt của các mô hình học sâu dựa trên Transformer trong việc xử lý các bài toán ngôn ngữ tự nhiên, đặc biệt là với tiếng Việt – một ngôn ngữ có đặc điểm phong phú về ngữ nghĩa, sắc thái biểu đạt và cấu trúc ngữ cảnh. Nhờ khả năng học biểu diễn ngữ cảnh sâu, PhoBERT có thể xử lý hiệu quả hơn các câu có cấu trúc phức tạp, các trường hợp phủ định,

các bình luận mang nhiều sắc thái cảm xúc, cũng như những câu mà cảm xúc không được thể hiện trực tiếp qua các từ khóa bề mặt.

Tuy nhiên, kết quả nghiên cứu cũng cho thấy mô hình **TF-IDF + Logistic Regression** vẫn có những giá trị thực tiễn đáng kể. Dù không đạt độ chính xác cao bằng PhoBERT, mô hình này có ưu điểm ở sự đơn giản, dễ triển khai, thời gian huấn luyện nhanh và chi phí tính toán thấp. Đây là những đặc điểm rất quan trọng trong các hệ thống thực tế có hạn chế về tài nguyên phần cứng hoặc yêu cầu tốc độ xử lý cao. Vì vậy, TF-IDF + Logistic Regression vẫn là một lựa chọn phù hợp trong các bài toán cân cân bằng giữa hiệu năng và chi phí triển khai, đồng thời cũng đóng vai trò là mô hình nền quan trọng để làm cơ sở đối chiếu với các mô hình hiện đại hơn.

Thông qua quá trình phân tích lỗi, đề án cũng đã chỉ ra một số thách thức nổi bật của bài toán phân loại cảm xúc văn bản tiếng Việt. Cụ thể, cả hai mô hình đều còn gặp khó khăn trong các trường hợp bình luận có cảm xúc yếu hoặc không rõ ràng, các câu chứa đồng thời nhiều ý khen chê, các cấu trúc phủ định phức tạp, các câu quá ngắn thiếu ngữ cảnh, cũng như các bình luận sử dụng từ lóng, emoji hoặc cách viết không chuẩn. Những kết quả này cho thấy rằng mặc dù các mô hình hiện nay đã đạt được hiệu quả khá tốt, bài toán phân tích cảm xúc tiếng Việt vẫn còn nhiều khó khăn cần tiếp tục được nghiên cứu và cải thiện.

Từ các kết quả đạt được, có thể khẳng định rằng đề án đã hoàn thành mục tiêu đề ra là xây dựng và so sánh hai mô hình tiêu biểu cho bài toán phân loại cảm xúc tiếng Việt, đồng thời đánh giá được ưu điểm, hạn chế và khả năng ứng dụng thực tế của từng mô hình. Kết quả nghiên cứu không chỉ có ý nghĩa về mặt học thuật trong việc minh họa sự khác biệt giữa hai hướng tiếp cận, mà còn có ý nghĩa thực tiễn trong việc hỗ trợ lựa chọn mô hình phù hợp cho các hệ thống phân tích đánh giá người dùng, giám sát phản hồi khách hàng hoặc khai thác dữ liệu bình luận trong thương mại điện tử.

Nhìn chung, nghiên cứu cho thấy **PhoBERT là mô hình phù hợp hơn khi ưu tiên chất lượng phân loại và khả năng hiểu ngữ nghĩa**, trong khi **TF-IDF + Logistic Regression phù hợp hơn trong các bối cảnh cần tốc độ, tính đơn giản và chi phí triển khai thấp**. Vì vậy, việc lựa chọn mô hình trong thực tế cần được cân nhắc dựa trên mục tiêu ứng dụng, điều kiện tài nguyên và yêu cầu về hiệu năng của hệ thống.

Hướng phát triển

Mặc dù đồ án đã đạt được những kết quả tích cực, vẫn còn nhiều hướng phát triển có thể tiếp tục nghiên cứu nhằm nâng cao chất lượng hệ thống phân loại cảm xúc tiếng Việt trong tương lai.

Trước hết, một hướng phát triển quan trọng là **thử nghiệm thêm các mô hình Transformer nâng cao hoặc các biến thể mới hơn** nhằm tiếp tục cải thiện hiệu năng phân loại. Bên cạnh PhoBERT, có thể xem xét các mô hình ngôn ngữ tiền huấn luyện khác dành cho tiếng Việt hoặc các kiến trúc đa ngôn ngữ mạnh hơn để so sánh và đánh giá. Việc mở rộng phạm vi thực nghiệm sang các mô hình mới sẽ giúp xác định được đâu là hướng tiếp cận tối ưu hơn cho từng loại dữ liệu và từng bối cảnh ứng dụng cụ thể.

Thứ hai, nghiên cứu có thể được mở rộng theo hướng **phân tích cảm xúc theo khía cạnh** (*Aspect-Based Sentiment Analysis*). Trong thực tế, nhiều bình luận của người dùng không chỉ thể hiện một cảm xúc chung mà thường chứa nhiều nhận xét khác nhau về các khía cạnh riêng biệt như chất lượng sản phẩm, giá cả, giao hàng, thái độ phục vụ hoặc chế độ bảo hành. Với các trường hợp như “sản phẩm đẹp nhưng giao hàng chậm”, việc chỉ gán một nhãn cảm xúc duy nhất cho toàn câu là chưa đủ để phản ánh đầy đủ nội dung. Do đó, phân tích cảm xúc theo khía cạnh sẽ là hướng đi có giá trị thực tiễn cao hơn, giúp hệ thống khai thác thông tin chi tiết và hữu ích hơn từ phản hồi người dùng.

Thứ ba, cần chú trọng hơn đến việc **mở rộng và làm giàu tập dữ liệu**. Chất lượng dữ liệu luôn là yếu tố có ảnh hưởng trực tiếp đến hiệu quả của mô hình. Trong tương lai, có thể thu thập thêm dữ liệu từ nhiều nguồn khác nhau như sàn thương mại điện tử, mạng xã hội, diễn đàn hoặc nền tảng đánh giá sản phẩm để tăng độ đa dạng cho ngữ liệu. Đồng thời, cần quan tâm đến vấn đề **cân bằng nhãn** giữa các lớp cảm xúc nhằm hạn chế hiện tượng lệch lớp, giúp mô hình học được đầy đủ hơn các đặc trưng của từng nhóm dữ liệu. Bên cạnh đó, việc xây dựng tập dữ liệu lớn hơn, chất lượng gán nhãn tốt hơn và phản ánh sát hơn ngôn ngữ thực tế sẽ giúp hệ thống có khả năng tổng quát hóa cao hơn khi triển khai.

Thứ tư, bước **tiền xử lý dữ liệu tiếng Việt** vẫn còn nhiều tiềm năng cải thiện. Trong môi trường bình luận trực tuyến, người dùng thường sử dụng từ lóng, ký hiệu kéo dài, emoji, viết tắt, cách viết sai chính tả hoặc pha trộn nhiều kiểu diễn đạt khác nhau. Đây là một trong những nguyên nhân khiến mô hình dễ mắc lỗi. Vì vậy, các nghiên cứu tiếp theo có

thể tập trung xây dựng các phương pháp chuẩn hóa văn bản hiệu quả hơn, xử lý tốt hơn các biểu thức không chuẩn, nhận diện từ lóng phổ biến, ánh xạ emoji sang cảm xúc tương ứng, cũng như cải thiện tách từ và làm sạch dữ liệu đầu vào. Một pipeline tiền xử lý phù hợp hơn với đặc trưng của ngôn ngữ mạng xã hội tiếng Việt có thể mang lại tác động tích cực đến hiệu năng mô hình.

Thứ năm, về khía cạnh ứng dụng, có thể nghiên cứu các phương pháp **tối ưu hóa mô hình để giảm chi phí tính toán** nhưng vẫn duy trì chất lượng dự đoán ở mức chấp nhận được. Đây là hướng đặc biệt cần thiết nếu muốn triển khai hệ thống trong thực tế, nhất là trên các nền tảng có tài nguyên hạn chế hoặc yêu cầu phản hồi nhanh. Một số hướng có thể cân nhắc bao gồm rút gọn mô hình, chưng cất tri thức (*knowledge distillation*), lượng tử hóa (*quantization*) hoặc lựa chọn các phiên bản nhẹ hơn của mô hình ngôn ngữ. Việc tối ưu này sẽ giúp thu hẹp khoảng cách giữa hiệu năng cao của mô hình học sâu và khả năng ứng dụng thực tế trong môi trường sản xuất.

Ngoài ra, trong tương lai có thể mở rộng nghiên cứu theo hướng **xây dựng hệ thống ứng dụng hoàn chỉnh**, chẳng hạn như một công cụ phân tích cảm xúc trực quan cho bình luận người dùng trên các nền tảng thương mại điện tử hoặc mạng xã hội. Khi đó, kết quả của mô hình không chỉ dừng ở mức thực nghiệm mà còn có thể hỗ trợ doanh nghiệp trong việc theo dõi phản hồi khách hàng, đánh giá chất lượng dịch vụ, phát hiện vấn đề phát sinh và đưa ra quyết định cải thiện sản phẩm. Đây là hướng phát triển có ý nghĩa thực tiễn cao, góp phần đưa kết quả nghiên cứu vào ứng dụng cụ thể.

Tóm lại, mặc dù đề án đã đạt được những kết quả khả quan, bài toán phân loại cảm xúc văn bản tiếng Việt vẫn còn nhiều tiềm năng nghiên cứu và cải tiến. Việc tiếp tục phát triển theo các hướng như nâng cấp mô hình, mở rộng dữ liệu, cải thiện tiền xử lý, phân tích cảm xúc theo khía cạnh và tối ưu triển khai sẽ góp phần nâng cao hơn nữa chất lượng và tính ứng dụng của hệ thống trong tương lai.

Tài liệu tham khảo

- [1]. **D. Jurafsky và J. H. Martin**, “*Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models*, 3rd edition (online manuscript)”, 2026.
- [2]. **C. D. Manning, P. Raghavan, và H. Schütze**, “*An Introduction to Information Retrieval*, Cambridge University Press, 2008” (bản online/draft có ghi Cambridge UP).
- [3]. **B. Liu**, *Sentiment Analysis and Opinion Mining*, Morgan & Claypool Publishers, 2012.
- [4]. **B. Pang, L. Lee, và S. Vaithyanathan**, “Thumbs up? Sentiment Classification using Machine Learning Techniques,” *EMNLP 2002*, Association for Computational Linguistics, 2002, tr. 79–86.
- [5]. **B. Pang và L. Lee**, “Opinion Mining and Sentiment Analysis,” *Foundations and Trends in Information Retrieval*, 2008.
- [6]. **F. Sebastiani**, “Machine Learning in Automated Text Categorization,” *ACM Computing Surveys*, 2002.
- [7]. **G. Salton và C. Buckley**, “Term-Weighting Approaches in Automatic Text Retrieval,” *Information Processing & Management*, vol. 24, no. 5, 1988, tr. 513–523.
- [8]. **C. Cortes và V. Vapnik**, “Support-vector networks,” *Machine Learning*, 1995.
- [9]. **T. Joachims**, “Text Categorization with Support Vector Machines: Learning with Many Relevant Features,” *ECML 1998* (Springer).
- [10]. **A. McCallum và K. Nigam**, “A Comparison of Event Models for Naive Bayes Text Classification,” *AAAI-98 Workshop on Learning for Text Categorization*, 1998.

- [11]. **F. Pedregosa và cs.**, “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research (JMLR)*, 2011.
- [12]. **T. Mikolov, I. Sutskever, K. Chen, G. Corrado, và J. Dean**, “Distributed Representations of Words and Phrases and their Compositionality,” 2013.
- [13]. **J. Pennington, R. Socher, và C. Manning**, “GloVe: Global Vectors for Word Representation,” *EMNLP 2014, ACL*, 2014, tr. 1532–1543.
- [14]. **P. Bojanowski, E. Grave, A. Joulin, và T. Mikolov**, “Enriching Word Vectors with Subword Information,” 2017
- [15]. **P. Quoc-Hung**, “Aspect-Based Sentiment Analysis of Clothing Reviews in Vietnamese E-commerce,” *PACLIC 38*, Tokyo University of Foreign Studies, 2024, tr. 231–238.
- [16]. **Q. L. Tran**, “Aspect-based Sentiment Analysis for Vietnamese Reviews about Beauty Product on E-commerce Websites,” *PACLIC 2022*, 2022.
- [17]. **D. Jurafsky and J. H. Martin**, *Speech and Language Processing*, 3rd ed. draft, Stanford University and University of Colorado Boulder, 2025/2026.
- [18]. **B. Liu**, *Sentiment Analysis and Opinion Mining*. Morgan & Claypool Publishers, 2012.
- [19]. **B. Pang, L. Lee, and S. Vaithyanathan**, “Thumbs up? Sentiment Classification using Machine Learning Techniques,” in *Proceedings of EMNLP 2002*, pp. 79–86, 2002.
- [20]. **A. Vaswani et al.**, “Attention Is All You Need,” 2017
- [21]. **D. Q. Nguyen and A. T. Nguyen**, “PhoBERT: Pre-trained language models for Vietnamese,” in *Findings of EMNLP 2020*, pp. 1037–1042, 2020.

PHỤ LỤC

A. Toàn bộ Notebook

Mã nguồn đầy đủ và quy trình thực nghiệm chi tiết được lưu trữ tại Google Colab Notebook dưới đây:

- **Link:** [LogisticRegression.ipynb](#), [PhoBert.ipynb](#)
- **Lưu ý:** Để chạy lại notebook, vui lòng tải bộ dữ liệu vào thư mục gốc của Drive hoặc upload trực tiếp lên session.
- **Link folder** làm việc của nhóm : [Đồ án chuyên ngành](#)